

ALGÈBRE LINÉAIRE IV

Table des matières

|          |                                                                |           |
|----------|----------------------------------------------------------------|-----------|
| <b>1</b> | <b>Brève introduction</b>                                      | <b>2</b>  |
| <b>2</b> | <b>Notions et propriétés fondamentales</b>                     | <b>2</b>  |
| 2.1      | Quelques rappels du semestre précédent . . . . .               | 2         |
| 2.2      | Le groupe multiplicatif des matrices orthogonales . . . . .    | 5         |
| 2.3      | Normes matricielles, conditionnement . . . . .                 | 7         |
| <b>3</b> | <b>Autour de la décomposition en valeurs singulières (SVD)</b> | <b>9</b>  |
| <b>4</b> | <b>Analyse en composantes principales</b>                      | <b>13</b> |
| <b>5</b> | <b>Une métrique adaptée</b>                                    | <b>18</b> |

## 1 Brève introduction

L'histoire de l'algèbre linéaire remonte à l'Antiquité, où les premières intuitions de cette discipline se manifestaient déjà. Les Babyloniens utilisaient vers 1800 avant J.-C. des méthodes proto-algébriques pour résoudre des systèmes d'équations linéaires, gravant dans l'argile les prémices de ce que nous connaissons actuellement.

Plus tard, les mathématiciens chinois de l'époque des Han, autour du IIe siècle avant J.-C., poursuivirent cette exploration avec le "Neuf Chapitres sur l'art mathématique", introduisant des techniques semblables aux méthodes matricielles omniprésentes aujourd'hui.

C'est au XIXe siècle que l'algèbre linéaire trouve sa source d'épanouissement, grâce à des pionniers comme Carl Friedrich Gauss et Augustin-Louis Cauchy qui apportèrent une rigueur et une structure formelle à ce domaine. L'algèbre linéaire rythme aujourd'hui le cœur battant des sciences et des technologies modernes.

C'est le langage des dimensions et l'âme de l'analyse numérique. Tandis que les vecteurs capturent l'essence des mouvements et des forces, les matrices orchestrent les transformations de ces vecteurs dans l'espace, façonnant la structure de l'information et encapsulant avec clarté tout morphisme.

En plus de vous permettre de comprendre en profondeur les tenants et les aboutissants de systèmes complexes, elle constitue la clef de voûte des algorithmes de Machine Learning : elle vous permet d'extraire des patterns, d'identifier des corrélations et de prédire l'avenir avec une précision remarquable.

Dans l'intégralité de ce cours, on considèrera  $n, p, q \in \mathbb{N}^*$ .

## 2 Notions et propriétés fondamentales

### 2.1 Quelques rappels du semestre précédent

**Cadre :**

On se place dans  $\mathbb{R}^n$  muni du produit scalaire euclidien défini par

$$\forall x, y \in \mathbb{R}^n, \quad \boxed{\langle x, y \rangle = \sum_{i=1}^n x_i y_i} \quad \text{où } x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \text{ et } y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}.$$

De plus, on définit

$$\forall x \in \mathbb{R}^n, \quad \boxed{\|x\|_2 = \sqrt{|\langle x, x \rangle|} = \sqrt{\sum_{i=1}^n x_i^2}},$$

appelée norme euclidienne de  $x$ . On définit également le réel positif

$$\forall x, y \in \mathbb{R}^n, \quad \boxed{d_2(x, y) = \|x - y\|_2}.$$

appelé distance euclidienne entre  $x$  et  $y$ .

**Proposition – Expression matricielle du produit scalaire :**

On a

$$\forall x, y \in \mathbb{R}^n, \quad \boxed{\langle x, y \rangle = y^\top x}.$$

**Preuve :**

Soient  $\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}, \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n$ . On a

$$\begin{aligned} y^\top x &= (y_1 \quad \cdots \quad y_n) \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \\ &= \sum_{i=1}^n y_i x_i \end{aligned} \quad \text{(Définition du produit matriciel)}$$

$$\begin{aligned}
 &= \sum_{i=1}^n x_i y_i && \text{(Commutativité du produit sur } \mathbb{R} \text{)} \\
 &= \langle x, y \rangle.
 \end{aligned}$$

**Remarque :**

Cette expression du produit scalaire est fondamentale et simplifie grandement les preuves de ce cours. Ceux qui ont le regard aiguisé auront bien entendu constaté que l'on a également

$$\forall x, y \in \mathbb{R}^n, \langle x, y \rangle = x^\top y,$$

cependant cette expression est bien moins pratique et ne correspond d'ailleurs plus au produit scalaire canonique lorsque l'on étend la définition à  $\mathbb{C}$ , mais c'est une autre histoire!

**Proposition – Transposée d'un produit de matrice :**

On a

$$\forall (A, B) \in \mathcal{M}_{n,p}(\mathbb{R}) \times \mathcal{M}_{p,q}(\mathbb{R}), \quad \boxed{(AB)^\top = B^\top A^\top}.$$

**Preuve :**

Considérons  $(A, B) \in \mathcal{M}_{n,p}(\mathbb{R}) \times \mathcal{M}_{p,q}(\mathbb{R})$ . On a

$$\forall (i, j) \in \llbracket 1, n \rrbracket \times \llbracket 1, q \rrbracket, \quad C_{ij} = \sum_{k=1}^p A_{ik} B_{kj}$$

En particulier

$$\begin{aligned}
 \forall (i, j) \in \llbracket 1, q \rrbracket \times \llbracket 1, n \rrbracket, \quad ((AB)^\top)_{ij} &= (C^\top)_{ij} \\
 &= C_{ji} \\
 &= \sum_{k=1}^p A_{jk} B_{ki}.
 \end{aligned}$$

Mais

$$\begin{aligned}
 \forall (i, j) \in \llbracket 1, q \rrbracket \times \llbracket 1, n \rrbracket, \quad (B^\top A^\top)_{ij} &= \sum_{k=1}^p (B^\top)_{ik} (A^\top)_{kj} \\
 &= \sum_{k=1}^p B_{ki} A_{jk} \\
 &= \sum_{k=1}^p A_{jk} B_{ki}
 \end{aligned}$$

Cela assure que chacun des coefficients des matrices  $(AB)^\top$  et  $B^\top A^\top$  sont égaux, d'où

$$\boxed{(AB)^\top = B^\top A^\top}.$$

**Proposition :**

Soit  $A \in \mathcal{M}_{n,p}(\mathbb{R})$ . Alors :

1.  $AA^\top$  et  $A^\top A$  sont des matrices symétriques (i.e.  $\boxed{(AA^\top)^\top = AA^\top}$  et  $\boxed{(A^\top A)^\top = A^\top A}$ ).
2.  $\boxed{\ker(A^\top A) = \ker(A)}$  et  $\boxed{\ker(AA^\top) = \ker(A^\top)}$ .
3.  $\boxed{\operatorname{rg}(A^\top A) = \operatorname{rg}(A)}$  et  $\boxed{\operatorname{rg}(AA^\top) = \operatorname{rg}(A^\top)}$ .
4.  $\boxed{\ker(A^\top) = \operatorname{Im}(A)^\perp}$ .
5.  $\boxed{\operatorname{rg}(A^\top) = \operatorname{rg}(A)}$ .
6.  $\forall \lambda \in \mathbb{R}^*, \quad \boxed{\lambda \in \operatorname{Sp}(AA^\top) \iff \lambda \in \operatorname{Sp}(A^\top A)}$ .

7.  $\forall \lambda \in \text{Sp}(A^\top A), \boxed{\lambda \geq 0}$ .

**Preuve :**

Soit  $A \in \mathcal{M}_{n,p}(\mathbb{R})$ .

1. La propriété précédente assure que

$$\begin{aligned}(AA^\top)^\top &= (A^\top)^\top A^\top \\ &= AA^\top.\end{aligned}$$

De même,

$$\begin{aligned}(A^\top A)^\top &= A^\top (A^\top)^\top \\ &= A^\top A.\end{aligned}$$

2. On a

$$\begin{aligned}x \in \ker(A) &\implies Ax = 0 \\ &\implies A^\top Ax = 0 \\ &\implies x \in \ker(A^\top A).\end{aligned}$$

Réciproquement,

$$\begin{aligned}x \in \ker(A^\top A) &\implies A^\top Ax = 0 \\ &\implies x^\top A^\top Ax = 0 \\ &\implies (Ax)^\top Ax = 0 \\ &\implies \langle Ax, Ax \rangle = 0 \\ &\implies \|Ax\|^2 = 0 \\ &\implies Ax = 0 \\ &\implies x \in \ker(A).\end{aligned}$$

Cela démontre que  $\boxed{\ker(A) = \ker(A^\top A)}$ . La démonstration de  $\boxed{\ker(A^\top) = \ker(AA^\top)}$  est analogue.

3. Le théorème du rang assure conjointement que

$$\begin{aligned}p &= \dim(\ker(A)) + \text{rg}(A), \\ p &= \dim(\ker(A^\top A)) + \text{rg}(A^\top A).\end{aligned}$$

Or, la relation précédente assurant que  $\ker(A) = \ker(A^\top A)$ , on en déduit que

$$\boxed{\text{rg}(A) = \text{rg}(A^\top A)}.$$

De même, le théorème du rang assure conjointement que

$$\begin{aligned}n &= \dim(\ker(A^\top)) + \text{rg}(A^\top), \\ n &= \dim(\ker(AA^\top)) + \text{rg}(AA^\top).\end{aligned}$$

Or, la relation précédente assurant que  $\ker(A^\top) = \ker(AA^\top)$ , on en déduit que

$$\boxed{\text{rg}(A^\top) = \text{rg}(AA^\top)}.$$

4. On a

$$\begin{aligned}x \in \ker(A^\top) &\iff A^\top x = 0 \\ &\iff \forall y \in \mathbb{R}^p, \langle A^\top x, y \rangle = 0 \quad (\text{Le vecteur nul est l'unique vecteur orthogonal à tout vecteur}) \\ &\iff \forall y \in \mathbb{R}^p, \langle x, Ay \rangle = 0 \quad (\text{Car } \langle A^\top x, y \rangle = y^\top A^\top x = (Ay)^\top x = \langle x, Ay \rangle) \\ &\iff x \in \text{Im}(A)^\perp \quad (\text{Car } \text{Im}(A) = \{Ay \mid y \in \mathbb{R}^p\})\end{aligned}$$

ce qui assure que  $\boxed{\ker(A^\top) = \text{Im}(A)^\perp}$ .

5. On a

$$\begin{aligned} n &= \dim(\text{Im}(A)) + \dim(\text{Im}(A)^\perp) & (\mathbb{R}^n &= \text{Im}(A) \oplus \text{Im}(A)^\perp) \\ &= \text{rg}(A) + \dim(\ker(A^\top)) & (\ker(A^\top) &= \text{Im}(A)^\perp) \\ &= \text{rg}(A) + (n - \text{rg}(A^\top)) & (\text{Théorème du rang}) \end{aligned}$$

Nécessairement  $\boxed{\text{rg}(A) = \text{rg}(A^\top)}$ .

6. Soit  $\lambda \in \mathbb{R}^*$ . On a

$$\begin{aligned} \lambda \in \text{Sp}(AA^\top) &\implies \exists x \neq 0, AA^\top x = \lambda x \\ &\implies \exists x \neq 0, A^\top A(A^\top x) = \lambda(A^\top x), \end{aligned}$$

ce qui veut exactement dire, si  $A^\top x \neq 0$ , que  $\lambda$  est valeur propre de  $A^\top A$ , et qu'un vecteur propre associé est  $A^\top x$ . Montrons alors que  $A^\top x \neq 0$  pour achever la preuve de l'implication.

Supposons par l'absurde que  $A^\top x = 0$ . Alors  $AA^\top x = 0$ , i.e.  $\lambda x = 0$ , donc  $\lambda = 0$  ou  $x = 0$ , ce qui est absurde dans chacun des cas par hypothèse. Nécessairement  $A^\top x \neq 0$ , ce qui achève la démonstration.

La preuve du sens réciproque est complètement analogue.

7. Soit  $\lambda \in \mathbb{R}$ . On a

$$\begin{aligned} \lambda \in \text{Sp}(A^\top A) &\implies \exists x \neq 0, A^\top A x = \lambda x, \\ &\implies x^\top A^\top A x = \lambda x^\top x \\ &\implies \langle Ax, Ax \rangle = \lambda \langle x, x \rangle \\ &\implies \|Ax\|^2 = \lambda \|x\|^2 \\ &\implies \lambda = \frac{\|Ax\|^2}{\|x\|^2} \geq 0. \end{aligned}$$

Notons que la division par  $\|x\|^2$  est permise car  $x \neq 0$ .

### Exemple :

Considérons

$$A = \begin{pmatrix} 2 & 0 \\ 0 & -3 \\ -1 & 1 \\ 1 & 1 \end{pmatrix}.$$

On a

$$A^\top A = \begin{pmatrix} 6 & 0 \\ 0 & 11 \end{pmatrix},$$

matrice symétrique réelle, donc diagonalisable en base orthonormée en vertu du théorème spectral. Les propriétés 2., 3. et 6. permettent ainsi d'affirmer que

$$\text{Sp}(AA^\top) = \{0, 6, 11\},$$

avec 0 valeur propre de multiplicité 2.

## 2.2 Le groupe multiplicatif des matrices orthogonales

### Définition :

Considérons  $M \in \mathcal{M}_n(\mathbb{R})$ . On dit que  $M$  est orthogonale lorsque

$$MM^\top = M^\top M = I_n.$$

Autrement dit,  $M$  est inversible et  $M^{-1} = M^\top$ . On note de plus  $\mathcal{O}_n(\mathbb{R})$  l'ensemble des matrices orthogonales.

### Proposition :

Soit  $M \in \mathcal{O}_n(\mathbb{R})$ . Alors :

1.  $\boxed{\det(M) = \pm 1}$ .
2.  $\forall x \in \mathbb{R}^n, \boxed{\|Mx\|_2 = \|x\|_2}$ .

**Preuve :**

Soit  $M \in \mathcal{O}_n(\mathbb{R})$ .

1. On a

$$\begin{aligned} \det(MM^\top) &= \det(I_n) && (\text{car } M \in \mathcal{O}_n(\mathbb{R})) \\ &= 1. \end{aligned}$$

Mais

$$\begin{aligned} \det(MM^\top) &= \det(M) \det(M^\top) && (\text{multiplicativité du déterminant}) \\ &= \det(M) \det(M) && (\text{car } \det(M^\top) = \det(M)) \\ &= (\det M)^2 \end{aligned}$$

Ainsi,

$$(\det M)^2 = 1.$$

Nécessairement

$$\boxed{\det(M) = \pm 1}.$$

2. Soit  $x \in \mathbb{R}^n$ . On a

$$\begin{aligned} \|Mx\|_2^2 &= \langle Mx, Mx \rangle \\ &= (Mx)^\top (Mx) \\ &= x^\top M^\top Mx && (\text{propriété de la transposée}) \\ &= x^\top x && (\text{car } M^\top M = I_n) \\ &= \langle x, x \rangle \\ &= \|x\|_2^2. \end{aligned}$$

Par positivité de la norme, on en déduit que

$$\boxed{\|Mx\|_2 = \|x\|_2}.$$

**Propriété – Stabilité de  $\mathcal{O}_n(\mathbb{R})$  par produit :**

On a

$$\forall P, Q \in \mathcal{O}_n(\mathbb{R}), PQ \in \mathcal{O}_n(\mathbb{R}).$$

**Preuve exigible :**

Soient  $P, Q \in \mathcal{O}_n(\mathbb{R})$ . On a

$$\begin{aligned} (PQ)^{-1} &= Q^{-1}P^{-1} \\ &= Q^\top P^\top && (\text{Car } P, Q \in \mathcal{O}_n(\mathbb{R})) \\ &= (PQ)^\top && (\text{Par propriété de la transposée}) \end{aligned}$$

Ainsi,  $PQ \in \mathcal{O}_n(\mathbb{R})$ .

**Propriété – Caractérisation des matrices orthogonales :**

Soit  $M \in \mathcal{M}_n(\mathbb{R})$ . Alors  $M \in \mathcal{O}_n(\mathbb{R})$  si et seulement si les colonnes de  $M$  forment une base orthonormée de  $\mathbb{R}^n$ .

**Preuve exigible :**

Soit  $M \in \mathcal{M}_n(\mathbb{R})$ . Notons  $C_1, \dots, C_n$  les colonnes de  $M$ . On a

$$\forall i, j \in \llbracket 1, n \rrbracket, (M^\top M)_{i,j} = \sum_{k=1}^n (M^\top)_{i,k} M_{k,j} \quad (\text{Définition du produit matriciel})$$

$$\begin{aligned}
 &= \sum_{k=1}^n M_{k,i} M_{k,j} \\
 &= \langle C_i, C_j \rangle,
 \end{aligned}$$

En particulier,

$$\begin{aligned}
 M \in \mathcal{O}_n(\mathbb{R}) &\iff M^\top M = I_n \iff \forall i, j \in \llbracket 1, n \rrbracket, (M^\top M)_{i,j} = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases} \\
 &\iff \forall i, j \in \llbracket 1, n \rrbracket, \langle C_i, C_j \rangle = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases} \\
 &\iff (C_1, \dots, C_n) \text{ forme une base orthonormée de } \mathbb{R}^n.
 \end{aligned}$$

ce qui achève la preuve.

### Exemple :

Les matrices

$$\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}, \quad \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix} \quad \text{et} \quad \begin{pmatrix} 1/\sqrt{2} & -1/\sqrt{3} & -1/\sqrt{6} \\ -1/\sqrt{2} & 1/\sqrt{3} & 1/\sqrt{6} \\ 0 & 1/\sqrt{3} & 2/\sqrt{6} \end{pmatrix}$$

sont des matrices orthogonales.

## 2.3 Normes matricielles, conditionnement

### Définition :

Soit  $A \in \mathcal{M}_{n,p}(\mathbb{R})$ . On définit la **norme subordonnée** de  $A$  par

$$|||A||| = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

### Proposition :

Soit  $(A, B) \in \mathcal{M}_{n,p}(\mathbb{R}) \times \mathcal{M}_{p,q}(\mathbb{R})$ . On a :

1.  $|||A||| = \max_{\|x\|=1} \|Ax\|_2$ .
2.  $|||AB||| \leq |||A||| \times |||B|||$ .
3. En notant  $\lambda_{\max}$  la plus grande valeur propre de  $A^\top A$ , on a  $|||A||| = \sqrt{\lambda_{\max}}$ .

### Preuve :

Soit  $(A, B) \in \mathcal{M}_{n,p}(\mathbb{R}) \times \mathcal{M}_{p,q}(\mathbb{R})$ .

1. On a

$$\begin{aligned}
 |||A||| &= \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} && \text{(Définition)} \\
 &= \max_{x \neq 0} \left\| A \cdot \frac{x}{\|x\|_2} \right\|_2 && \text{(Homogénéité de } \|\cdot\|_2) \\
 &= \max_{\|y\|_2=1} \|Ay\|_2 && (y = \frac{x}{\|x\|_2} \text{ est unitaire)}
 \end{aligned}$$

2. On a

$$\begin{aligned}
 \forall x \in \mathbb{R}^q, \|ABx\|_2 &= \|A(Bx)\|_2 \\
 &\leq |||A||| \|Bx\|_2 && \text{(définition de } |||A|||) \\
 &\leq |||A||| |||B||| \|x\|_2 && \text{(définition de } |||B|||).
 \end{aligned}$$

Donc

$$\forall x \in \mathbb{R}^q \setminus \{0\}, \frac{\|ABx\|_2}{\|x\|_2} \leq \|A\| \|B\|.$$

Par conséquent

$$\begin{aligned} \|AB\| &= \max_{x \neq 0} \frac{\|ABx\|_2}{\|x\|_2} \\ &\leq \|A\| \|B\|. \end{aligned}$$

3. **Exigible** On a

$$\begin{aligned} \|A\| &= \max_{\|x\|_2=1} \|Ax\|_2 && \text{(Propriété 1.)} \\ &= \max_{\|x\|_2=1} \sqrt{\langle Ax, Ax \rangle} \\ &= \max_{\|x\|_2=1} \sqrt{\langle A^\top Ax, x \rangle}. \end{aligned}$$

$A^\top A$  étant symétrique réelle, elle est diagonalisable en base orthonormée en vertu du théorème spectral, il existe donc  $P \in \mathcal{O}_p(\mathbb{R})$  et  $D = \text{Diag}(\lambda_1, \dots, \lambda_p)$  où  $\lambda_1, \dots, \lambda_p \in \text{Sp}(A^\top A)$  telles que

$$A^\top A = PDP^\top.$$

Pour tout  $x \in \mathbb{R}^p$  unitaire, on a donc

$$\begin{aligned} \langle A^\top Ax, x \rangle &= \langle PDP^\top x, x \rangle \\ &= \langle DP^\top x, P^\top x \rangle \\ &= \langle Dy, y \rangle && \text{(On pose } y = P^\top x) \\ &= \sum_{i=1}^p \lambda_i y_i^2 && (D = \text{diag}(\lambda_1, \dots, \lambda_p)) \\ &\leq \lambda_{\max} \sum_{i=1}^p y_i^2 && (\lambda_{\max} = \max(\lambda_1, \dots, \lambda_p)) \\ &= \lambda_{\max} \|y\|_2^2 \\ &= \lambda_{\max} && (y \text{ est unitaire}). \end{aligned}$$

Par conséquent

$$\max_{\|x\|_2=1} \langle A^\top Ax, x \rangle \leq \lambda_{\max}.$$

Considérons désormais  $v$  un vecteur propre unitaire associé à  $\lambda_{\max}$ , i.e.

$$A^\top Av = \lambda_{\max} v.$$

Alors

$$\begin{aligned} \langle A^\top Av, v \rangle &= \langle \lambda_{\max} v, v \rangle \\ &= \lambda_{\max} \langle v, v \rangle \\ &= \lambda_{\max}. \end{aligned}$$

Nécessairement

$$\max_{\|x\|_2=1} \langle A^\top Ax, x \rangle = \lambda_{\max}.$$

Ainsi

$$\boxed{\|A\| = \sqrt{\lambda_{\max}}}.$$



### 3 Autour de la décomposition en valeurs singulières (SVD)

#### Définition :

On se place sur  $\mathcal{M}_{n,p}(\mathbb{R})$ , et on le muni du **produit scalaire de Frobenius** défini par

$$\forall A, B \in \mathcal{M}_{n,p}(\mathbb{R}), \langle A, B \rangle_F = \text{Tr}(A^\top B) = \sum_{i=1}^n \sum_{j=1}^p A_{ij} B_{ij}$$

La norme associée, appelée **norme de Frobenius**, est donnée par

$$\forall A \in \mathcal{M}_{n,p}(\mathbb{R}), \|A\|_F = \sqrt{\langle A, A \rangle_F} = \sqrt{\sum_{i=1}^n \sum_{j=1}^p A_{ij}^2}.$$

On définit de plus la **distance de Frobenius** entre deux matrices par

$$\forall A, B \in \mathcal{M}_{n,p}(\mathbb{R}), d_F(A, B) = \|A - B\|.$$

#### Théorème :

Soient  $n, p \in \mathbb{N}^*$ . Considérons  $M \in \mathcal{M}_{n,p}(\mathbb{R})$ . Alors il existe  $(U, V) \in \mathcal{O}_n(\mathbb{R}) \times \mathcal{O}_p(\mathbb{R})$  et il existe d'unique réels  $\sigma_1 \geq \dots \geq \sigma_r > 0$  (où  $r = \text{rg}(M)$ ) tels que

$$M = U \Sigma V^T,$$

où  $\Sigma \in \mathcal{M}_{n,p}(\mathbb{R})$  désigne la matrice par bloc définie par


$$\left( \begin{array}{cccc|c} \sigma_1 & 0 & \cdots & 0 & \mathbf{0}_{r,p-r} \\ 0 & \sigma_2 & \ddots & \vdots & \\ \vdots & \ddots & \ddots & 0 & \\ 0 & \cdots & 0 & \sigma_r & \\ \hline \mathbf{0}_{n-r,r} & & & & \mathbf{0}_{n-r,p-r} \end{array} \right) \in \mathcal{M}_{n,p}(\mathbb{R}).$$

On appelle cette décomposition de  $M$  la **décomposition en valeurs singulières de  $M$** , et les réels  $\sigma_i$ , où  $i \in \llbracket 1, r \rrbracket$ , sont appelés **valeurs singulières de  $M$** .

#### Remarque :

La décomposition en valeurs singulières est une décomposition remarquable car elle s'applique à toute matrice, sans aucune hypothèse préalable. Par ailleurs, elle peut être vue comme un analogue de la diagonalisation.

Géométriquement, la décomposition en valeurs singulières exprime une transformation linéaire  $M$  donnée comme la composée de trois transformations linéaires simples : une isométrie  $V^T$ , suivie d'une dilatation selon des directions orthogonales  $\Sigma$ , puis d'une seconde isométrie  $U$ .



**Preuve :**

Soit  $M \in \mathcal{M}_{n,p}(\mathbb{R})$  une matrice de rang  $r$ .

Puisque  $M^\top M \in \mathcal{M}_p(\mathbb{R})$  est positive et que  $\text{rg}(M^\top M) = \text{rg}(M) = r$ , on a

$$\text{Sp}(M^\top M) = \left\{ \underbrace{\lambda_1, \dots, \lambda_r}_{>0}, \underbrace{\lambda_{r+1}, \dots, \lambda_p}_{=0} \right\},$$

et  $M^\top M$  étant symétrique, le théorème spectral assure que

$$\exists V \in \mathcal{O}_p(\mathbb{R}), \quad M^\top M = V \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \lambda_p \end{pmatrix} V^\top.$$

Quitte à renuméroter les valeurs propres de  $M^\top M$ , on peut supposer que  $\lambda_1 \geq \dots \geq \lambda_r$ . Puisqu'elles sont strictement positives, il existe d'unique réels  $\sigma_1 \geq \dots \geq \sigma_r > 0$  tels que

$$\forall i \in \llbracket 1, r \rrbracket, \quad \lambda_i = \sigma_i^2.$$

Posons alors

$$\Sigma = \left( \begin{array}{cccc|c} \sigma_1 & 0 & \cdots & 0 & \mathbf{0}_{r,p-r} \\ 0 & \sigma_2 & & \vdots & \\ \vdots & \ddots & \ddots & 0 & \\ 0 & \cdots & 0 & \sigma_r & \\ \hline & \mathbf{0}_{n-r,r} & & & \mathbf{0}_{n-r,p-r} \end{array} \right) \in \mathcal{M}_{n,p}(\mathbb{R}), \quad \text{où } \forall i \in \llbracket 1, r \rrbracket, \quad \sigma_i = \sqrt{\lambda_i}.$$

Afin d'achever la preuve, construisons  $U \in \mathcal{O}_n(\mathbb{R})$  telle que

$$M = U \Sigma V^\top,$$

ce qui est équivalent à construire  $U \in \mathcal{O}_n(\mathbb{R})$  telle que

$$MV = U \Sigma,$$

autrement dit, en notant  $u_i$  (resp.  $v_i$ ) les vecteurs colonnes de  $U$  (resp.  $V$ ), on cherche une base orthonormée de  $\mathbb{R}^n$  telle que

$$\forall i \in \llbracket 1, r \rrbracket, \quad Mv_i = \sigma_i u_i \quad \text{et} \quad \forall i \in \llbracket r+1, p \rrbracket, \quad Mv_i = 0,$$

la seconde condition étant d'ores et déjà assurée car

$$\forall i \in \llbracket r+1, p \rrbracket, \quad v_i \in \ker(A^\dagger) = \ker(A).$$

Posons

$$\forall i \in \llbracket 1, r \rrbracket, \quad u_i = \frac{1}{\sigma_i} Mv_i \in \mathbb{R}^n,$$

et montrons que  $(u_1, \dots, u_r)$  est une famille orthonormée de vecteurs de  $\mathbb{R}^n$ . On a

$$\begin{aligned} \forall i, j \in \llbracket 1, r \rrbracket, \quad i \neq j &\implies \langle u_i, u_j \rangle = \frac{1}{\sigma_i \sigma_j} \langle Mv_i, Mv_j \rangle \\ &= \frac{1}{\sigma_i \sigma_j} \langle v_i, M^\top M v_j \rangle \\ &= \frac{1}{\sigma_i \sigma_j} \langle v_i, \lambda_j v_j \rangle \\ &= \frac{\sigma_j^2}{\sigma_i \sigma_j} \langle v_i, v_j \rangle \\ &= \begin{cases} 1 & \text{si } i = j, \\ 0 & \text{sinon.} \end{cases} \end{aligned}$$

On complète alors  $(u_1, \dots, u_r)$  en une base orthonormée de  $\mathbb{R}^n$  et le tour est joué!

**Corollaire – SVD réduite :**

Soient  $n, p \in \mathbb{N}^*$ . Considérons  $M \in \mathcal{M}_{n,p}(\mathbb{R})$ . Alors il existe  $(U, V) \in \mathcal{O}_n(\mathbb{R}) \times \mathcal{O}_p(\mathbb{R})$  et il existe d'unique réels  $\sigma_1 \geq \dots \geq \sigma_r > 0$  (où  $r = \text{rg}(M)$ ) tels que

$$M = U_r \Sigma_r V_r^T,$$

où  $U_r \in \mathcal{M}_{n,r}(\mathbb{R})$  (resp.  $V_r \in \mathcal{M}_{p,r}(\mathbb{R})$ ) désigne la matrice formée des  $r$  premières colonnes de  $U$  (resp. de  $V$ ), et où  $\Sigma_r \in \mathcal{M}_r(\mathbb{R})$  désigne la matrice diagonale définie par

$$\begin{pmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \sigma_r \end{pmatrix} \in \mathcal{M}_r(\mathbb{R}).$$

On appelle cette décomposition de  $M$  la **décomposition en valeurs singulières réduite de  $M$** .

#### Méthode – Déterminer la SVD réduite d'une matrice donnée :

Soient  $n, p \in \mathbb{N}^*$ . Quitte à transposer, on part du postulat que  $n \geq p$ . Considérons  $A \in \mathcal{M}_{n,p}(\mathbb{R})$ . Les étapes afin de déterminer  $U_r, \Sigma_r, V_r$  telles que  $A = U_r \Sigma_r V_r$  sont :

1. Expliciter  $A$ .
2. Déterminer  $\text{Sp}(A^T A)$ , par passage à la racine on construit  $\Sigma_r$ .
3. Expliciter  $E_\lambda$  pour tout  $\lambda \in \text{Sp}(A^T A)$  afin d'en déduire les colonnes de  $V_r$ .
4. En notant  $u_i$  (resp.  $v_i$ ) les colonnes de  $U_r$  (resp.  $V_r$ ) pour tout  $i \in \llbracket 1, r \rrbracket$ , on a

$$u_i = \frac{1}{\sigma_i} A v_i.$$

#### Exemple :

Considérons

$$A = \begin{pmatrix} 3 & -2 & -1 \\ 0 & 2 & -1 \\ 0 & 0 & -2 \\ 1 & 2 & 1 \end{pmatrix}$$

On a

$$A^T A = \begin{pmatrix} 10 & -4 & -2 \\ -4 & 12 & 2 \\ -2 & 2 & 7 \end{pmatrix}.$$

En particulier,

$$\begin{aligned} \chi_{A^T A}(X) &= \det \begin{pmatrix} 10-X & -4 & -2 \\ -4 & 12-X & 2 \\ -2 & 2 & 7-X \end{pmatrix} \\ &= \det \begin{pmatrix} 6-X & 0 & 12-2X \\ -4 & 12-X & 2 \\ -2 & 2 & 7-X \end{pmatrix} && L_1 + 2L_3 \\ &= \det \begin{pmatrix} 6-X & 0 & 0 \\ -4 & 12-X & 10 \\ -2 & 2 & 11-X \end{pmatrix} && C_3 - 2C_1 \\ &= (6-X) \det \begin{pmatrix} 12-X & 10 \\ 2 & 11-X \end{pmatrix} \\ &= (6-X)((12-X)(11-X) - 20) \\ &= (6-X)(X^2 - 23X + 112) \\ &= (6-X)(X-7)(X-16). \end{aligned}$$

Ainsi, les valeurs singulières de  $A$  sont 4,  $\sqrt{7}$  et  $\sqrt{6}$ . En étudiant les sous-espaces propres de  $A^T A$ , on obtient :

$$E_{16} = \text{Vect} \left( \begin{pmatrix} 4 \\ -5 \\ -2 \end{pmatrix} \right), \quad E_7 = \text{Vect} \left( \begin{pmatrix} 2 \\ 2 \\ -1 \end{pmatrix} \right), \quad E_6 = \text{Vect} \left( \begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix} \right).$$

On déduit ainsi la décomposition en valeurs singulières réduite  $A = U_r \Sigma_r V_r^T$ , avec :

$$U_r = \begin{pmatrix} \frac{6}{3\sqrt{5}} & \frac{3}{3\sqrt{7}} & \frac{1}{\sqrt{30}} \\ -\frac{3\sqrt{5}}{2} & \frac{3\sqrt{7}}{5} & -\frac{\sqrt{30}}{4} \\ \frac{1}{3\sqrt{5}} & \frac{2}{3\sqrt{7}} & -\frac{3}{\sqrt{30}} \\ -\frac{3\sqrt{5}}{2} & \frac{3\sqrt{7}}{5} & \frac{3}{\sqrt{30}} \end{pmatrix}, \quad \Sigma_r = \begin{pmatrix} 4 & 0 & 0 \\ 0 & \sqrt{7} & 0 \\ 0 & 0 & \sqrt{6} \end{pmatrix}, \quad V_r = \begin{pmatrix} \frac{4}{3\sqrt{5}} & \frac{2}{3} & \frac{1}{\sqrt{5}} \\ -\frac{3\sqrt{5}}{2} & \frac{2}{3} & 0 \\ -\frac{3\sqrt{5}}{2} & -\frac{1}{3} & \frac{2}{\sqrt{5}} \end{pmatrix}.$$

### Exercice :

Déterminer les SVD réduites des matrices suivantes :

$$A = \begin{pmatrix} 1 & 3 \\ 3 & 2 \\ -3 & 1 \\ 0 & 0 \end{pmatrix} \quad B = \begin{pmatrix} -3 & 0 & -4 \\ 0 & 0 & -4 \\ -2 & -1 & 1 \\ -2 & -1 & -1 \\ 0 & -3 & 3 \end{pmatrix}.$$

### Propriété – Invariance par transformation orthogonale de la norme de Frobenius :

Soit  $M \in \mathcal{M}_{n,p}(\mathbb{R})$  une matrice de rang  $r$ . En notant  $\sigma_1, \dots, \sigma_r$  les valeurs singulières de  $M$ , on a

$$\|M\|_F^2 = \sum_{i=1}^r \sigma_i^2.$$

### Théorème – Eckart-Young :

Soient  $n, p \in \mathbb{N}^*$ . Considérons  $M \in \mathcal{M}_{n,p}(\mathbb{R})$  matrice de rang  $r$ , et  $U\Sigma V^T$  sa décomposition en valeurs singulières. On pose

$$\forall k \in \llbracket 1, r \rrbracket, \Sigma_k = \left( \begin{array}{cccc|c} \sigma_1 & 0 & \cdots & 0 & \mathbf{0}_{k,p-k} \\ 0 & \sigma_2 & \ddots & \vdots & \\ \vdots & \ddots & \ddots & 0 & \\ 0 & \cdots & 0 & \sigma_k & \\ \hline \mathbf{0}_{n-k,k} & & & & \mathbf{0}_{n-k,p-k} \end{array} \right) \in \mathcal{M}_{n,p}(\mathbb{R}) \quad \text{et} \quad M_k = U\Sigma_k V^T.$$

Alors  $M_k$  est de rang  $k$ , en notant  $u_i$  (resp.  $v_i$ ) les vecteurs colonnes de  $U$  (resp.  $V$ ) on a

$$M_k = \sum_{i=1}^k \sigma_i u_i v_i^T$$

et

$$\min_{\substack{B \in \mathcal{M}_{n,p}(\mathbb{R}) \\ \text{rg}(B)=k}} \|M - B\| = \|M - M_k\|$$

i.e.  $M_k$  est la meilleure approximation de rang  $k$  de  $M$ .

### Preuve :

Pour tout  $k \in \llbracket 1, r \rrbracket$ ,  $\text{rg}(M_k) = \text{rg}(\Sigma_k) = k$ .

Si  $(e_1, \dots, e_n)$  désigne la base canonique de  $\mathbb{R}^n$  et  $(f_1, \dots, f_p)$  celle de  $\mathbb{R}^p$ , on peut écrire

$$\forall k \in \llbracket 1, r \rrbracket, \Sigma_k = \sum_{i=1}^k \sigma_i e_i f_i^T.$$

Ainsi

$$\begin{aligned} \forall k \in \llbracket 1, r \rrbracket, M_k &= U\Sigma_k V^T = U \left( \sum_{i=1}^k \sigma_i e_i f_i^T \right) V^T \\ &= \sum_{i=1}^k \sigma_i U e_i f_i^T V^T \end{aligned}$$

$$\begin{aligned} &= \sum_{i=1}^k \sigma_i (U e_i) (V f_i)^\top \\ &= \sum_{i=1}^k \sigma_i u_i v_i^\top \end{aligned}$$

Soit  $B \in \mathcal{M}_{n,p}(\mathbb{R})$  telle que  $\text{rg}(B) = k$ . Posons

$$C = U^\top B V.$$

Comme  $U$  et  $V$  sont inversibles (car orthogonales), on a  $\text{rg}(C) = \text{rg}(B) = k$  et, par invariance de la norme spectrale par multiplication orthogonale,

$$\begin{aligned} \|M - B\|_2 &= \|U^\top (M - B) V\|_2 \\ &= \|\Sigma - C\|_2. \end{aligned}$$

Ainsi

$$\min_{\substack{B \in \mathcal{M}_{n,p}(\mathbb{R}) \\ \text{rg}(B)=k}} \|M - B\|_2 = \min_{\substack{C \in \mathcal{M}_{n,p}(\mathbb{R}) \\ \text{rg}(C)=k}} \|\Sigma - C\|_2.$$

Comme  $\text{rg}(C) = k$ , le noyau de  $C$  est de dimension au moins  $p - k$ . On admet (ce n'est pas trivial) qu'il existe un vecteur unitaire

$$x \in \text{Vect}(f_{k+1}, \dots, f_p) \cap \ker(C).$$

On a alors

$$(\Sigma - C)x = \Sigma x.$$

Donc

$$\|\Sigma - C\| \geq \sigma_{k+1}.$$

et le minimum est atteint en  $C = \Sigma_k$  ! Finalement

$$\min_{\substack{B \in \mathcal{M}_{n,p}(\mathbb{R}) \\ \text{rg}(B)=k}} \|M - B\|_2 = \|M - M_k\|_2 = \sigma_{k+1}.$$

Donc  $M_k$  est la meilleure approximation de rang  $k$  de  $M$ , et l'erreur d'approximation est  $\sigma_{k+1}$ .

## 4 Analyse en composantes principales

### Définition :

Considérons  $X \in \mathcal{M}_{n,p}(\mathbb{R})$  modélisant les observations de  $n$  réalisations dépendant de  $p$  variables réelles.

On dit que  $X$  est **centrée** lorsque

$$\forall j \in \llbracket 1, p \rrbracket, \frac{1}{n} \sum_{i=1}^n X_{ij} = 0.$$

Auquel cas, on appelle **matrice de covariance empirique associée à  $X$**  la matrice définie par

$$\Sigma = \frac{1}{n} X^\top X.$$

On appelle **axes principaux** les vecteurs propres  $u_1, \dots, u_p$  associées aux valeurs propres  $\lambda_1, \dots, \lambda_p$  de la matrice de covariance  $\Sigma$ , et on appelle **composantes principales** de  $X$  les vecteurs de  $\mathbb{R}^n$  définis par

$$\forall k \in \llbracket 1, p \rrbracket, Z_k = X u_k.$$

De plus, on appelle **matrice des scores** la matrice  $Z$  dont les colonnes sont les  $Z_k$ .

Finalement, on appelle **inertie totale de  $X$**  le réel

$$I_{\text{tot}} = \frac{1}{n} \sum_{i=1}^n \|(X_c)_i\|^2, \quad \text{où } (X_c)_i \text{ désigne la ligne } i \text{ de } X.$$

### Remarque fondamentale :

Étant donné  $X \in \mathcal{M}_{n,p}(\mathbb{R})$  la matrice des observations de  $p$  variables réelles sur  $n$  réalisations, centrer  $X$  revient à placer le barycentre du nuage des observations en l'origine de  $\mathbb{R}^p$ .

Centrer  $X$  signifie que, pour toute colonne  $j \in \llbracket 1, p \rrbracket$  de  $X$ , on soustrait la moyenne empirique

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n X_{ij}$$

à toutes les observations de la colonne  $j$ . Autrement dit, chaque donnée est remplacée par son écart à la moyenne. En particulier,

$$\forall i, j \in \llbracket 1, p \rrbracket, \Sigma_{ij} = \frac{1}{n} \sum_{k=1}^n X_{ki} X_{kj}$$

correspond à la covariance empirique des colonnes  $i$  et  $j$  et mesure à quel point les variables  $i$  et  $j$  fluctuent ensemble. Si  $i = j$ ,  $\Sigma_{ii}$  correspond à la variance empirique de la colonne  $i$ .

L'analyse porte ainsi uniquement sur la façon dont les individus varient les uns par rapport aux autres : c'est précisément cette variabilité que mesurent  $\Sigma$ , les axes principaux et les composantes principales.

$I_{\text{tot}}$  est parfois appelée **variance totale de  $X$** , et mesure l'ampleur globale des fluctuations de  $X$ .

### Propriété :

Considérons  $X_c \in \mathcal{M}_{n,p}(\mathbb{R})$  centrée, et  $u \in \mathbb{R}^p$  un vecteur unitaire. Alors

$$u^T \Sigma u = \mathbb{V}(X_c u).$$

où  $\mathbb{V}(X_c u)$  désigne la variance empirique du vecteur  $X_c u$ . De plus,

$$I_{\text{tot}} = \sum_{i=1}^p \lambda_i \quad \text{où } \lambda_i \in \text{Sp} \left( \frac{1}{n} X_c^T X_c \right).$$

### Preuve :

- On a

$$\begin{aligned} u^T \Sigma u &= \frac{1}{n} u^T X_c^T X_c u \\ &= \frac{1}{n} \|X_c u\|^2 \\ &= \frac{1}{n} \sum_{i=1}^n (X_c u)_i^2. \end{aligned}$$

Or le vecteur  $X_c u$  est centré (combinaison linéaire de colonnes centrées), donc sa moyenne empirique vaut 0 et, par définition de la variance empirique,

$$\mathbb{V}(X_c u) = \frac{1}{n} \sum_{i=1}^n ((X_c u)_i - 0)^2 = \frac{1}{n} \sum_{i=1}^n (X_c u)_i^2.$$

Ainsi,

$$u^T \Sigma u = \mathbb{V}(X_c u).$$

- En vertu de la définition de l'inertie totale :

$$\begin{aligned} I_{\text{tot}} &= \frac{1}{n} \sum_{i=1}^n \|X_c)_i\|^2 \\ &= \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^p (X_c)_{ij}^2 \\ &= \frac{1}{n} \sum_{j=1}^p \sum_{i=1}^n (X_c)_{ij}^2. \end{aligned}$$

Mais la quantité  $\sum_{i=1}^n (X_c)_{ij}^2$  est exactement le  $j$ -ième terme diagonal de  $X_c^\top X_c$ , d'où

$$I_{\text{tot}} = \frac{1}{n} \text{tr}(X_c^\top X_c) = \text{tr}\left(\frac{1}{n} X_c^\top X_c\right) = \text{tr}(\Sigma) = \sum_{i=1}^p \lambda_i.$$

### Remarque :

Considérons  $X \in \mathcal{M}_{n,p}(\mathbb{R})$  modélisant les observations de  $n$  réalisations dépendant de  $p$  variables réelles. En considérant  $\sigma_1, \dots, \sigma_p$  les valeurs singulières de  $X$ , on a

$$I_{\text{tot}} = \frac{1}{n} \sum_{i=1}^p \sigma_i^2.$$

### Méthode – ACP :

Considérons  $X \in \mathcal{M}_{n,p}(\mathbb{R})$  modélisant les observations de  $n$  réalisations dépendant de  $p$  variables réelles. Pour une direction unitaire  $u \in \mathbb{R}^p$  ( $\|u\| = 1$ ), la projection des individus sur l'axe  $\mathbb{R}u$  est le vecteur

$$X_c u \in \mathbb{R}^n,$$

dont la variance mesure l'étalement du nuage dans cette direction. On cherche la direction dans laquelle le nuage est le plus étalé, ce qui revient à résoudre le problème d'optimisation

$$\max_{\|u\|=1} \mathbb{V}(X_c u).$$

Or, la propriété précédente assure que  $\mathbb{V}(X_c u) = u^\top \Sigma u$ ; le problème revient donc à maximiser  $u^\top \Sigma u$  sur la boule unité. Nous verrons en TD (exercice sur le quotient de Rayleigh) que les maximiseurs sont les vecteurs propres associés aux plus grandes valeurs propres : le vecteur unitaire associé à la première composante principale maximise le problème initial, puis les suivantes se déduisent en imposant des contraintes d'orthogonalité.

L'**Analyse en Composantes Principales** (ACP) est une méthode de **réduction de dimension** qui, à partir du nuage de points centré, projette les individus sur des axes orthonormés maximisant successivement la variance projetée. Sa mise en œuvre repose sur l'étude spectrale de la matrice de covariance

$$\Sigma = \frac{1}{n} X_c^\top X_c,$$

puis sur la projection des données sur les  $k$  premières composantes principales. Les étapes clefs sont :

1. Centrage : À partir de la matrice de données  $X \in \mathcal{M}_{n,p}(\mathbb{R})$ , on soustrait à chaque colonne sa moyenne empirique afin d'obtenir une matrice centrée notée  $X_c$  :

$$\forall (i, j) \in \llbracket 1, n \rrbracket \times \llbracket 1, p \rrbracket, \quad X_{ij} \leftarrow X_{ij} - \frac{1}{n} \sum_{k=1}^n X_{kj}.$$

*Si on ne centre pas, la variance empirique sera mesurée autour de l'origine, et non autour de la moyenne, ce qui est souvent peu représentatif.*

2. Étude spectrale : Déterminer et diagonaliser en base orthonormée

$$\Sigma = \frac{1}{n} X_c^\top X_c \in \mathcal{M}_p(\mathbb{R}).$$

On note  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$  les valeurs propres de  $\Sigma$  et  $(v_1, \dots, v_p)$  une base orthonormée de vecteurs propres associée.

3. Calibrage : On fixe un entier  $k \leq p$ .

On calcule la **proportion de variance expliquée par les  $k$  premières composantes principales**, définie par

$$\rho_k = \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j}.$$

Le numérateur représente la variance conservée par la projection sur les  $k$  premières composantes, tandis que le dénominateur correspond à la variance totale du nuage de points.  $\rho_k \in [0, 1]$  mesure ainsi la qualité de la représentation obtenue, le choix de  $k$  résultant d'un compromis entre réduction de dimension et perte d'information.

4. Projection : Les données projetées sont

$$Z = X_c V_k \in \mathcal{M}_{n,k}(\mathbb{R}), \quad V_k = (v_1, \dots, v_k).$$

On appelle souvent score de l'individu  $r$  sur la composante  $i$  le coefficient  $Z_{r,i}$ .

5. Interprétation : Les axes principaux correspondent aux directions de plus grande variance, et les coordonnées de  $Z$  fournissent une représentation de dimension réduite du nuage de points conservant au mieux sa structure.

**Exemple :**

Considérons

$$A = \begin{pmatrix} -11 & -9 & -3 \\ -4 & 9 & 2 \\ -9 & -9 & -5 \\ 0 & 5 & 6 \end{pmatrix}.$$

La matrice  $A$  centrée est donnée par

$$A_c = \begin{pmatrix} -5 & -8 & -3 \\ 2 & 10 & 2 \\ -3 & -8 & -5 \\ 6 & 6 & 6 \end{pmatrix}.$$

On a

$$\Sigma = \frac{1}{4} A_c^T A_c = \frac{1}{4} \begin{pmatrix} 74 & 120 & 70 \\ 120 & 264 & 120 \\ 70 & 120 & 74 \end{pmatrix},$$

en particulier,  $\text{Sp}(4\Sigma) = \{384, 24, 4\}$  donc  $\text{Sp}(\Sigma) = \{96, 6, 1\}$ . De plus,

$$v_{96} = \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix} \quad v_6 = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix} \quad v_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}$$

sont des vecteurs propres associés aux valeurs propres de  $\Sigma$ . On a également

$$I_{\text{tot}} = 96 + 6 + 1 = 103.$$

Disons que l'on fixe  $k = 2$ , on obtient

$$\frac{96 + 6}{96 + 6 + 1} \approx 99\% \text{ de variance expliquée par les deux premières composantes principales.}$$

On projette à l'aide de

$$V_2 = \begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & -\frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \end{pmatrix},$$

Ainsi

$$Z = \begin{pmatrix} -5 & -8 & -3 \\ 2 & 10 & 2 \\ -3 & -8 & -5 \\ 6 & 6 & 6 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & -\frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \end{pmatrix} = \begin{pmatrix} -4\sqrt{6} & 0 \\ 4\sqrt{6} & -2\sqrt{3} \\ -4\sqrt{6} & 0 \\ 4\sqrt{6} & 2\sqrt{3} \end{pmatrix}.$$

Les lignes de  $Z$  correspondent aux coordonnées des 4 individus projetées sur  $\text{Vect}(v_{96}, v_6)$ .

**Exercice :**

Effectuer une ACP des matrices, i.e. déterminer les composantes principales, l'inertie totale, ainsi que la proportion de variance expliquée par  $k = 2$  composantes principales :

$$A = \begin{pmatrix} -2 & -5 & -1 \\ 2 & -5 & -4 \\ 3 & 1 & 3 \\ -4 & 1 & 2 \\ -4 & -2 & -5 \end{pmatrix} \quad B = \begin{pmatrix} 4 & 2 & -1 \\ 1 & -2 & -1 \\ 3 & 4 & 4 \\ -2 & 4 & 4 \\ 4 & -3 & 4 \end{pmatrix} \quad C = \begin{pmatrix} 4 & 3 & -4 \\ 4 & 0 & -1 \\ -2 & 1 & 2 \\ 4 & -3 & -1 \\ 4 & -2 & 5 \\ -2 & -5 & -1 \end{pmatrix}.$$



On a

$$A_c = \begin{pmatrix} -1 & -3 & 0 \\ 3 & -3 & -3 \\ 4 & 3 & 4 \\ -3 & 3 & 3 \\ -3 & 0 & -4 \end{pmatrix} \quad B_c = \begin{pmatrix} 2 & 1 & -3 \\ -1 & -3 & -3 \\ 1 & 3 & 2 \\ -4 & 3 & 2 \\ 2 & -4 & 2 \end{pmatrix} \quad C_c = \begin{pmatrix} 2 & 4 & -4 \\ 2 & 1 & -1 \\ -4 & 2 & 2 \\ 2 & -2 & -1 \\ 2 & -1 & 5 \\ -4 & -4 & -1 \end{pmatrix}.$$

Donc

$$\Sigma_A = \frac{1}{5} \begin{pmatrix} 44 & -3 & 10 \\ -3 & 36 & 30 \\ 10 & 30 & 50 \end{pmatrix}, \quad \Sigma_B = \frac{1}{5} \begin{pmatrix} 26 & -12 & -5 \\ -12 & 44 & 10 \\ -5 & 10 & 30 \end{pmatrix}, \quad \Sigma_C = \begin{pmatrix} 8 & 2 & -1 \\ 2 & 7 & -2 \\ -1 & -2 & 8 \end{pmatrix}$$

On effectue une étude spectrale de chacune de ces matrices.

- $\text{Sp}(\Sigma_A) = \{15, 9, 2\}$ , et les vecteurs propres associés sont

$$v_{15} = \frac{1}{\sqrt{26}} \begin{pmatrix} 1 \\ 3 \\ 4 \end{pmatrix}, \quad v_9 = \frac{1}{\sqrt{10}} \begin{pmatrix} 3 \\ -1 \\ 0 \end{pmatrix}, \quad v_2 = \frac{1}{\sqrt{65}} \begin{pmatrix} 2 \\ 6 \\ -5 \end{pmatrix}.$$

- $\text{Sp}(\Sigma_B) = \{11, 5, 4\}$ , et les vecteurs propres associés sont

$$v_{11} = \frac{1}{\sqrt{6}} \begin{pmatrix} -1 \\ 2 \\ 1 \end{pmatrix}, \quad v_5 = \frac{1}{\sqrt{30}} \begin{pmatrix} 1 \\ -2 \\ 5 \end{pmatrix}, \quad v_4 = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}.$$

- $\text{Sp}(\Sigma_C) = \{11, 7, 5\}$ , et les vecteurs propres associés sont

$$v_{11} = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ -1 \end{pmatrix}, \quad v_7 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}, \quad v_5 = \frac{1}{\sqrt{6}} \begin{pmatrix} -1 \\ 2 \\ 1 \end{pmatrix}$$

Ainsi, pour  $k = 2$ , les matrices des coordonnées des individus sur les composantes principales sont

$$Z_A = \begin{pmatrix} -\frac{10}{\sqrt{26}} & 0 \\ \frac{\sqrt{26}}{18} & \frac{12}{\sqrt{10}} \\ -\frac{\sqrt{26}}{29} & \frac{\sqrt{10}}{9} \\ \frac{\sqrt{26}}{18} & \frac{\sqrt{10}}{12} \\ \frac{\sqrt{26}}{19} & -\frac{\sqrt{10}}{9} \\ -\frac{\sqrt{26}}{\sqrt{26}} & -\frac{\sqrt{10}}{\sqrt{10}} \end{pmatrix}, \quad Z_B = \begin{pmatrix} -\frac{3}{\sqrt{6}} & -\frac{15}{\sqrt{30}} \\ \frac{\sqrt{6}}{8} & -\frac{\sqrt{30}}{10} \\ -\frac{\sqrt{6}}{7} & -\frac{\sqrt{30}}{5} \\ \frac{\sqrt{6}}{12} & \frac{\sqrt{30}}{\sqrt{30}} \\ \frac{\sqrt{6}}{8} & 0 \\ -\frac{\sqrt{6}}{\sqrt{6}} & \frac{20}{\sqrt{30}} \end{pmatrix}, \quad Z_C = \begin{pmatrix} \frac{10}{\sqrt{3}} & -\frac{2}{\sqrt{2}} \\ \frac{\sqrt{3}}{4} & \frac{1}{\sqrt{2}} \\ \frac{\sqrt{3}}{4} & \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{3}}{1} & -\frac{\sqrt{2}}{1} \\ \frac{\sqrt{3}}{4} & \frac{1}{\sqrt{2}} \\ -\frac{\sqrt{3}}{7} & \frac{\sqrt{2}}{5} \\ -\frac{\sqrt{3}}{\sqrt{3}} & -\frac{\sqrt{2}}{\sqrt{2}} \end{pmatrix}.$$

Les inerties totales sont données par

$$I_A = 26, \quad I_B = 20, \quad I_C = 23.$$

Les proportions de variance expliquée par les 2 premières composantes sont données par

$$\rho_A = \frac{12}{13} \quad \rho_B = \frac{16}{20} \quad \rho_C = \frac{18}{23}$$

## 5 Une métrique adaptée

### Définition :

Considérons  $x, y \in \mathbb{R}^p$ , et  $\Sigma$  une matrice symétrique inversible positive. On définit

$$d_M : (x, y) \mapsto \sqrt{(x - y)^\top \Sigma^{-1} (x - y)},$$

appelée **distance de Mahalanobis** entre  $x$  et  $y$  associée à  $\Sigma$ .

### Proposition :

Considérons  $x, y \in \mathbb{R}^p$ , et  $\Sigma$  une matrice symétrique inversible positive. Alors

$$\forall x, y \in \mathbb{R}^p, \quad d_M(x, y) = \|\Sigma^{-\frac{1}{2}}(x - y)\|_2$$

### Preuve :

Considérons  $x, y \in \mathbb{R}^p$ , et  $\Sigma \in \mathcal{M}_p(\mathbb{R})$  une matrice symétrique inversible positive. En vertu du théorème spectral, il existe  $Q \in \mathcal{O}_p(\mathbb{R})$  telle que  $\Sigma = Q \text{Diag}(\sigma_1, \dots, \sigma_p) Q^\top$ , où  $\sigma_1 \geq \dots \geq \sigma_p > 0$ .

On peut définir

$$\Sigma^{\frac{1}{2}} = Q \text{Diag}(\sqrt{\sigma_1}, \dots, \sqrt{\sigma_p}) Q^\top.$$

De même, on peut définir

$$\Sigma^{-\frac{1}{2}} = Q \text{Diag}(1/\sqrt{\sigma_1}, \dots, 1/\sqrt{\sigma_p}) Q^\top.$$

À noter que ces deux matrices sont symétriques par construction. Ainsi

$$\begin{aligned} \forall x, y \in \mathbb{R}^p, \quad d_M(x, y) &= \sqrt{(x - y)^\top \Sigma^{-1} (x - y)} \\ &= \sqrt{(x - y)^\top \Sigma^{-\frac{1}{2}} \Sigma^{-\frac{1}{2}} (x - y)} \\ &= \sqrt{(\Sigma^{-\frac{1}{2}}(x - y))^\top \Sigma^{-\frac{1}{2}}(x - y)} \\ &= \sqrt{\langle \Sigma^{-\frac{1}{2}}(x - y), \Sigma^{-\frac{1}{2}}(x - y) \rangle} \\ &= \sqrt{\|\Sigma^{-\frac{1}{2}}(x - y)\|_2^2} \\ &= \|\Sigma^{-\frac{1}{2}}(x - y)\|_2. \end{aligned}$$

### Remarque :

Supposons que  $X \in \mathcal{M}_{n,p}(\mathbb{R})$  modélise un jeu de données de  $n$  observations décrites par  $p$  variables. On note

$$\mu = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_p \end{pmatrix} \in \mathbb{R}^p$$

le vecteur des moyennes des colonnes  $1, 2, \dots, p$  de  $X$ , et  $\Sigma$  la matrice de covariance empirique de  $X$ , supposée inversible. On a

$$\forall i \in \llbracket 1, n \rrbracket, \forall x_i \in \mathbb{R}^p, \quad d(x_i, \mu) = \sqrt{(x_i - \mu)^\top \Sigma^{-1} (x_i - \mu)}.$$

où  $x_i$  désigne la  $i$ -ème observation décrite par les  $p$  variables. En particulier, si le jeu de données est centré,  $\mu$  est le vecteur nul, et on a

$$\forall i \in \llbracket 1, n \rrbracket, \forall x_i \in \mathbb{R}^p, \quad d(x_i, \mu) = \sqrt{x_i^\top \Sigma^{-1} x_i}.$$

La distance euclidienne correspond à la norme induite par le produit scalaire canonique, et coïncide avec la distance de Mahalanobis associée à la matrice identité. Elle modélise ainsi une géométrie isotrope, dans laquelle toutes les directions de l'espace sont pondérées de manière identique.

Lorsque les données possèdent une structure de covariance non triviale, **cette géométrie n'est plus adaptée** : certaines directions présentent une dispersion plus importante que d'autres, et des corrélations peuvent exister.

La distance de Mahalanobis induit une métrique **dépendant des covariances**, adaptée aux données observées  $X$  car elle tient compte des corrélations. La proposition précédente assure qu'il s'agit de la norme euclidienne couplée à l'isomorphisme  $\Sigma^{-1/2}$ , ce qui permet de corriger l'anisotropie et ainsi mesurer les écarts relativement aux variances propres du jeu de données considéré.