

ALGÈBRE LINÉAIRE IV

Table des matières

0	Organisation du cours et progression indicative	2
1	Introduction	3
2	S'entraîner à la SVD	5
3	Projections et interprétation géométrique	12
4	Comprendre le machine learning	14
5	Distances généralisées et métriques adaptées	16
6	Optionnel	18

0 Organisation du cours et progression indicative

Progression indicative :

- **Partie I** : 12 heures
- **Partie II** : 21 heures
- **Parties III & IV** : 9 heures
- **Partie V** : 12 heures
- **Durée totale** : 56 heures

Les modalités d'évaluation sont les suivantes :

- **9 février 2026**
 - Après 3 semaines de cours
 - QCM (8 questions)
 - Durée : 30 minutes
 - Périmètre (qui inclut des notions d'algèbre linéaire III) :
 1. Propriétés des matrices symétriques
 2. Projections orthogonales, matrices de projections
 3. Procédé de Gram-Schmidt
 4. Sous-espaces stables
 5. Bases orthonormées
 6. Norme de Frobenius
 7. Rang d'une application linéaire
 - Support : Evalmee
- **9 mars 2026**
 - Après 6 semaines de cours
 - Examen écrit
 - Durée : 60 minutes
 - Périmètre :
 1. Exercice 1 : cours et théorie
 2. Exercice 2 : SVD et variance
 - Support : papier
- **Juin 2026**
 - Après la fin du chapitre
 - Examen écrit
 - Durée : 120 minutes
 - Périmètre : tous les exercices non étoilés
 - Support : papier

Quelques ressources supplémentaires :

1. MATHEMATICS FOR MACHINE LEARNING
 - (a) Il explique très bien l'algèbre linéaire pour l'apprentissage automatique.
 - (b) Il contient également des exercices qui ont inspiré certains de ceux du TD.
2. Une super playlist youtube
 - (a) Cette liste de lecture contient des applications pratiques (python) de la SVD, qui peuvent être étudiées en classe.
3. Présentation de l'analyse en composantes principales
 - (a) Ce pdf, disponible sur inside, complète le plan avec les principaux résultats pratiques de ce chapitre.

1 Introduction

Exercice 1 (Le B.A BA)

On considère $\mathcal{M}_n(\mathbb{R})$ muni du produit scalaire canonique.

Soit $A \in \mathcal{M}_n(\mathbb{R})$.

1. Montrer que :

$$0 \in \text{Sp}(A) \iff A \text{ n'est pas inversible}$$

2. On suppose ici que A est symétrique. Soient $\lambda, \mu \in \text{Sp}(A)$ telles que $\lambda \neq \mu$.

Montrer que E_λ et E_μ sont des sous-espaces vectoriels orthogonaux de $\mathbb{R}^n$.

Exercice 2 (Le B.A BA 2.0)

Soit $A \in \mathcal{M}_{n,p}(\mathbb{R})$.

1. Montrer que AA^T et $A^T A$ sont des matrices **symétriques**. Préciser l'ensemble auquel elles appartiennent.
2. Soit $\lambda \in \mathbb{R}^*$. Démontrer que :

$$\lambda \in \text{Sp}(AA^T) \iff \lambda \in \text{Sp}(A^T A)$$

3. Soit $\lambda \in \mathbb{R}$. Montrer que si $\lambda \in \text{Sp}(AA^T)$ alors $\lambda \geq 0$.

Exercice 3 (Produit scalaire matriciel et norme de Frobenius)

On rappelle que sur $\mathcal{M}_{n,p}(\mathbb{R})$, on définit un produit scalaire par

$$\langle A, B \rangle_F = \text{Tr}(A^T B).$$

La norme associée, appelée norme de Frobenius, est donnée par

$$\|A\|_F = \sqrt{\langle A, A \rangle_F} = \sqrt{\text{Tr}(A^T A)}$$

1. (a) Exprimer $\langle A, B \rangle_F$ en fonction des coefficients de A et de B .
(b) En déduire que $\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2}$, et préciser les ensembles d'indices pour i et j .
2. Calculer la norme de Frobenius de

$$A = \begin{pmatrix} 1 & 2 \\ 3 & -1 \end{pmatrix}.$$

3. Calculer la distance de Frobenius entre

$$A = \begin{pmatrix} 1 & 2 \\ 3 & -1 \end{pmatrix} \quad \text{et} \quad B = \begin{pmatrix} 0 & 1 \\ 2 & 2 \end{pmatrix}.$$

4. Pour tout λ réel, on pose :

$$M(\lambda) = \begin{pmatrix} \lambda & 0 \\ 0 & 1 \end{pmatrix},$$

- (a) Exprimer la distance entre A et $M(\lambda)$ en fonction de λ .
- (b) Pour quelle(s) valeur(s) de λ cette distance est-elle minimale?

Exercice 4 (Matrice normale)

Soit $A \in \mathcal{M}_n(\mathbb{R})$. On dit que A est normale si $AA^\top = A^\top A$.

1. Vérifier que toute matrice symétrique ou orthogonale est normale.
2. Donner un exemple de matrice normale qui n'est ni symétrique ni orthogonale.
3. Montrer que si A est normale, alors $\|Ax\|_2 = \|A^\top x\|_2$ pour tout $x \in \mathbb{R}^n$.
4. (★) La réciproque de la propriété précédente est-elle vraie ?

Exercice 5 (Boules unités pour différentes normes)

On travaille dans $\mathbb{R}^2$ et on considère les normes suivantes :

$$\|x\|_1 = |x_1| + |x_2|, \quad \|x\|_2 = \sqrt{x_1^2 + x_2^2}, \quad \|x\|_\infty = \max(|x_1|, |x_2|).$$

1. Représenter graphiquement dans le plan les trois “boules unités” associées à ces normes. On fera trois repères séparés.
2. Montrer que pour tout $x \in \mathbb{R}^2$, on a

$$\|x\|_\infty \leq \|x\|_2 \leq \|x\|_1.$$

3. En déduire les inclusions entre les trois boules.

Exercice 6 (Adjoint d'une application linéaire)

Soit $E = \mathbb{R}^n$ muni du produit scalaire canonique $\langle x, y \rangle = x^\top y$. On considère une application linéaire $f : E \rightarrow E$ de matrice A dans la base canonique.

1. Montrer qu'il existe une unique application linéaire f^* telle que

$$\forall x, y \in E, \quad \langle f(x), y \rangle = \langle x, f^*(y) \rangle.$$

2. Préciser la matrice de f^* dans la base canonique.
3. En déduire que $f = f^*$ si et seulement si A est symétrique.

Exercice 7 (Sous-espaces stables)

Soit $A \in \mathcal{M}_n(\mathbb{R})$ et $E = \mathbb{R}^n$. On dit qu'un sous-espace $F \subset E$ est stable par A si $A(F) \subset F$.

1. Montrer que si u est un vecteur propre de A , alors $\text{Vect}(u)$ est un sous-espace stable.
2. Soit $A = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix}$. Trouver tous les sous-espaces stables de $\mathbb{R}^2$ pour A .
3. Montrer que si A admet une base de vecteurs propres, alors $\mathbb{R}^n$ est somme directe des sous-espaces stables engendrés par ces vecteurs.
4. Interpréter géométriquement le lien entre “sous-espaces stables” et “axes de diagonalisation”.

Exercice 8 (Décomposition en parties symétrique et antisymétrique – partie I)

On considère l'espace vectoriel $\mathcal{M}_n(\mathbb{R})$ des matrices réelles $n \times n$.

On note :

$$\mathcal{S}_n = \{A \in \mathcal{M}_n(\mathbb{R}) \mid A^\top = A\} \quad \text{et} \quad \mathcal{A}_n = \{A \in \mathcal{M}_n(\mathbb{R}) \mid A^\top = -A\}.$$

Montrons, par analyse-synthèse, que toute matrice $M \in \mathcal{M}_n(\mathbb{R})$ peut s'écrire de manière unique comme la somme d'une matrice symétrique et d'une matrice antisymétrique.

1. Analyse : On suppose qu'il existe $S \in \mathcal{S}_n$ et $A \in \mathcal{A}_n$ tels que

$$M = S + A.$$

(a) Exprimer M^T en fonction de S et A .

(b) En déduire une expression de S et de A en fonction de M et M^T .

2. Synthèse : Pour une matrice M donnée, donner alors $S \in \mathcal{S}_n$ et $A \in \mathcal{A}_n$ tels que

$$M = S + A.$$

3. Conclure.

4. Calculer explicitement la décomposition symétrique et antisymétrique de

$$M = \begin{pmatrix} 2 & 5 & 1 \\ 0 & 3 & -2 \\ -1 & 4 & 1 \end{pmatrix}.$$

Exercice 9 (Décomposition en parties symétrique et antisymétrique – partie II)

On considère l'espace vectoriel $\mathcal{M}_n(\mathbb{R})$ des matrices réelles $n \times n$, muni du produit scalaire de Frobenius :

$$\langle A, B \rangle = \text{Tr}(A^T B).$$

On note :

$$\mathcal{S}_n = \{A \in \mathcal{M}_n(\mathbb{R}) \mid A^T = A\} \quad \text{et} \quad \mathcal{A}_n = \{A \in \mathcal{M}_n(\mathbb{R}) \mid A^T = -A\}.$$

1. Montrer que $\mathcal{S}_n$ et $\mathcal{A}_n$ sont des sous-espaces vectoriels de $\mathcal{M}_n(\mathbb{R})$.
2. Déterminer les dimensions de ces deux sous-espaces vectoriels.
3. Montrer que $\mathcal{S}_n \cap \mathcal{A}_n = \{0\}$.
4. En déduire que

$$\mathcal{M}_n(\mathbb{R}) = \mathcal{S}_n \oplus \mathcal{A}_n.$$

5. En déduire un lien entre cet exercice et l'exercice précédent.
6. Montrer que $\mathcal{S}_n$ et $\mathcal{A}_n$ sont orthogonaux pour le produit scalaire de Frobenius.

2 S'entraîner à la SVD

Exercice 10 (Matrice de covariance)

On considère deux séries statistiques de n observations, représentées sous la forme d'une matrice A de taille $(n, 2)$, où chaque colonne correspond aux valeurs observées d'une variable :

$$A = \begin{bmatrix} x_1 & y_1 \\ \vdots & \vdots \\ x_n & y_n \end{bmatrix}$$

Plusieurs de ces questions pourront être traitées en faisant intervenir un symbole « somme » : Σ

1. Donner une expression de la moyenne $\bar{x}$ des valeurs de la première colonne.
2. Définir la version centrée des données, notée A_c , et en donner une expression.
3. Exprimer explicitement les termes de la matrice $A_c^T A_c$.

4. Rappeler l'expression explicite de la variance $\text{Var}(X)$ et de la covariance $\text{Cov}(X, Y)$ dans le cadre des séries statistiques.
5. Donner l'expression de la matrice de covariance de A .

Exercice 11 (SVD et variance)

Utiliser cet outil pour visualiser le jeu de données.

Soit X le jeu de données :

$$\begin{bmatrix} 2 & 2 \\ 0 & 2 \\ 3 & 3 \\ -1 & 1 \end{bmatrix}$$

1. Calculer la moyenne de chaque colonne et construire la matrice centrée X_c .
2. Calculer la variance de chaque colonne du jeu de données.
3. Calculer l'inertie du jeu de données (c'est-à-dire la variance totale du jeu de données).
4. La SVD du jeu de données centré X_c est donnée par :

$$U = \begin{bmatrix} -0.27 & 0.65 \\ 0.27 & -0.65 \\ -0.65 & -0.27 \\ 0.65 & ? \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 3.41 & 0.00 \\ 0.00 & 0.59 \end{bmatrix}, \quad V^T = \begin{bmatrix} -0.92 & -0.38 \\ 0.38 & -0.92 \end{bmatrix}$$

En utilisant cette décomposition :

- (a) Donner, en justifiant, la valeur manquante « ? ».
- (b) Donner la première composante du jeu de données.
- (c) Calculer la proportion de variance capturée par la première composante principale.
- (d) Calculer par une seconde méthode l'inertie du jeu de données.

Exercice 12

Déterminer la décomposition en valeurs singulières (SVD) de la matrice

$$A = \begin{pmatrix} 1 & 1 \\ -1 & 0 \\ 0 & -1 \end{pmatrix} \in \mathcal{M}_{3,2}(\mathbb{R}).$$

Exercice 13 (Maximiser $v^T A v$ et étude des vecteurs propres pour une matrice 2×2)

Soit A une matrice symétrique 2×2 ayant pour valeurs propres $\lambda_1 \geq \lambda_2 \geq 0$ et pour vecteurs propres orthonormés associés v_1 et v_2 .

Soit V un vecteur unitaire ($\|V\| = 1$).

Suivre les étapes ci-dessous pour démontrer que la valeur maximale de $V^T A V$ correspond à la plus grande valeur propre λ_1 .

1. Diagonaliser la matrice A .
2. Soit (α, β) les coordonnées de V dans la base (v_1, v_2) .
Justifier que $\alpha^2 + \beta^2 = 1$.
3. Exprimer $V^T A V$ en fonction de $\lambda_1, \lambda_2, \alpha, \beta$.
4. Exprimer $V^T A V$ en fonction de $\lambda_1, \lambda_2, \alpha$.
5. Pour quelle(s) valeur(s) de α la quantité $V^T A V$ est-elle maximale ?
Vous pouvez poser $\alpha^2 = x$ et étudier la fonction en la dérivant.

6. Quelle est la valeur maximale de $V^T A V$ et pour quelle valeur de V est-elle atteinte ?

Exercice 14 (Décomposition en valeurs singulières vs diagonalisation)

Soit la matrice A suivante :

$$A = \begin{pmatrix} 1 & 2 \\ 1 & 2 \end{pmatrix}$$

1. Déterminer les valeurs singulières de A et déterminer sa décomposition en valeurs singulières (SVD).
2. Déterminer les valeurs propres de A et la diagonaliser.
3. Pourquoi peut-on s'attendre à ce que les deux décompositions soient différentes ? Expliquer les différences.

Exercice 15 (Décomposition en valeurs singulières vs diagonalisation)

Soit la matrice A suivante :

$$A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$$

1. Déterminer les valeurs singulières de A et déterminer sa décomposition en valeurs singulières (SVD).
2. Déterminer les valeurs propres de A et la diagonaliser.
3. Pourquoi peut-on s'attendre à ce que les deux décompositions soient identiques ? Expliquer.

Exercice 16 (Décomposition en valeurs singulières et approximation de rang faible)

Soit le jeu de données X suivant :

$$X = \begin{bmatrix} 4 & 7 \\ 2 & 6 \\ 8 & 10 \\ 2 & 5 \end{bmatrix}$$

1. Calculer la moyenne de chaque colonne et construire la matrice centrée X_c .
2. Calculer la variance de chaque colonne du jeu de données.
3. Calculer l'inertie du jeu de données, définie comme la variance totale (somme des variances des colonnes).
4. La décomposition en valeurs singulières (SVD) du jeu de données centré X_c est donnée par :

$$U = \begin{bmatrix} -0.00 & -0.84 \\ 0.36 & -0.73 \\ -0.81 & 0.06 \\ 0.46 & 0.68 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 6.14 & 0 \\ 0 & 0.56 \end{bmatrix}$$

$$V^T = \begin{bmatrix} 0.60 & -0.80 \\ 0.80 & 0.60 \end{bmatrix}$$

En utilisant cette décomposition :

- (a) Construire l'approximation de rang 1 X_1 de X_c à partir de sa SVD.
- (b) Calculer la proportion de variance via la première composante principale.
- (c) Calculer la variance totale du jeu de données et vérifier qu'elle correspond à la somme des carrés des valeurs singulières.
- (d) Quel est l'impact de l'utilisation de l'approximation de rang 1 ? En quoi simplifie-t-elle le jeu de données ?
- (e) Supposons que l'on veuille une approximation de rang 2 à la place. Serait-elle significativement meilleure que celle de rang 1 ? Justifier votre réponse.

Exercice 17 (Décomposition en valeurs singulières et variance)

Soit le jeu de données X suivant :

$$X = \begin{bmatrix} 2 & 3 \\ 3 & 6 \\ 7 & 9 \end{bmatrix}$$

- 1. Calculer la moyenne de chaque colonne et construire la matrice centrée X_c .
- 2. Calculer la variance de chaque colonne du jeu de données.
- 3. Calculer l'inertie du jeu de données (c'est-à-dire la variance totale).
- 4. La décomposition en valeurs singulières (SVD) du jeu de données centré X_c est donnée par :

$$U = \begin{bmatrix} -0.64 & 0.51 \\ -0.12 & -0.81 \\ 0.76 & 0.30 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 5.58 & 0 \\ 0 & 0.93 \end{bmatrix}$$

$$V = \begin{bmatrix} 0.60 & -0.80 \\ 0.80 & 0.60 \end{bmatrix}$$

En utilisant cette décomposition :

- (a) Construire l'approximation de rang 1 X_1 de X_c à partir de sa SVD.
- (b) Calculer la proportion de variance via la première composante principale.
- (c) Quelle est la variance totale du jeu de données ? En quoi est-elle liée à la somme des carrés des valeurs singulières ?

Exercice 18

En utilisant les informations de l'exercice précédent :

- 1. Calculer le barycentre (ou centre de gravité) du jeu de données, c'est-à-dire la moyenne des points.
- 2. Déterminer l'équation de la droite la plus proche du jeu de données au sens de l'Analyse en Composantes Principales (ACP).
Indication : utiliser la première composante principale issue de la décomposition en ACP.
- 3. Tracer le nuage de points du jeu de données et superposer la première composante principale.

Exercice 19 (Exercice de synthèse)

Dans tout l'exercice $\mathcal{M}_{n,p}(\mathbb{R})$ désignera l'ensemble des matrices de taille $n \times p$ à coefficients dans $\mathbb{R}$. En particulier, $\mathcal{M}_{n,1}(\mathbb{R})$ désignera l'ensemble des vecteurs colonnes de taille n .

A] Étude d'une matrice

Une célèbre école de data science évalue six étudiants à travers trois projets répartis sur un semestre. Selon leur niveau d'implication, ils reçoivent un certain score décrit par le tableau suivant :

Score	Signification
-2	Aucune contribution
-1	Contribution très partielle
0	Minimum syndical atteint
+1	Idee intéressante à approfondir
+2	Solution remarquable, unanimement saluée

Les résultats du semestre sont modélisés par la matrice $A \in \mathcal{M}_{6,3}(\mathbb{R})$ suivante :

$$A = \begin{pmatrix} -1 & -2 & -1 \\ 2 & -2 & 1 \\ 1 & -1 & 1 \\ -2 & -2 & 1 \\ 0 & 1 & 1 \\ 0 & 2 & -2 \end{pmatrix}$$

On étudie d'abord $B := A^T A \in \mathcal{M}_3(\mathbb{R})$. On note $\mathcal{B}_c = (e_1, e_2, e_3)$ la base canonique de $\mathcal{M}_{3,1}(\mathbb{R})$.

1. Dans cette question, on réalise une étude spectrale de B .
 - a) Expliciter soigneusement f_B l'endomorphisme canoniquement associé à B .
 - b) Déterminer $f_B(e_1 - e_2 - 2e_3)$. En déduire une première valeur propre de B .
 - c) Étudier $\ker(B - 11I_3)$. En déduire une deuxième valeur propre de B .
 - d) En déduire que $\text{Sp}(B) = \{5, 11, 21\}$ puis que l'endomorphisme f_B est bijectif.
 - e) Justifier que B est diagonalisable dans une base orthonormée de vecteurs propres (notée $\mathcal{B}'$), et diagonaliser B dans cette base. On précisera :

$$D = \text{Mat}_{\mathcal{B}'}(f_B), \quad P = P_{\mathcal{B}_c \rightarrow \mathcal{B}'}, \quad P^{-1} = P_{\mathcal{B}' \rightarrow \mathcal{B}_c}$$

2. On pose $C = AA^T$.

- a) Expliciter la matrice C .
- b) Déduire de 1.d) le spectre de C , puis le rang de C (noté $\text{rg}(C)$).
- c) Vérifier que la famille suivante est une base de $\ker(C)$.

$$\mathcal{B}_k = \left(\begin{pmatrix} 8 \\ 0 \\ 0 \\ -4 \\ 10 \\ -1 \end{pmatrix}, \begin{pmatrix} 0 \\ 2 \\ 0 \\ 2 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 8 \\ 4 \\ 2 \\ 7 \end{pmatrix} \right)$$

3. (a) Donner les matrices $\Sigma \in \mathcal{M}_{6,3}(\mathbb{R})$ et $V \in \mathcal{M}_3(\mathbb{R})$ de la décomposition en valeurs singulières (SVD) de la matrice A .

(b) On donne ici les trois premières colonnes de la matrice U :

$$U_1 = \frac{1}{\sqrt{105}} \begin{pmatrix} -3 \\ -5 \\ -3 \\ -5 \\ 1 \\ 6 \end{pmatrix}, U_2 = \frac{1}{\sqrt{330}} \begin{pmatrix} -9 \\ 10 \\ 6 \\ -10 \\ 3 \\ -2 \end{pmatrix}, U_3 = \frac{1}{\sqrt{30}} \begin{pmatrix} 3 \\ 2 \\ 0 \\ -2 \\ -3 \\ 2 \end{pmatrix}$$

Donner 3 arguments pour justifier que la valeur donnée pour U_1 est cohérente avec vos connaissances de la SVD.

B] Application

On suppose désormais que les deux « 0 » sont en réalité des valeurs manquantes (mauvaise communication entre l'école et les étudiants...).

1. Expliquer comment la SVD que vous venez de faire peut permettre de donner une estimation de ces valeurs manquantes.
2. En déduire une estimation possible des deux notes manquantes. Voir cet article [medium](#).
3. On vous fait remarquer qu'une ACP aurait sans doute été plus pertinente qu'une SVD. Qu'en pensez-vous ? Donner une réponse argumentée de quelques lignes, qui soulignera les différences entre ACP et SVD.

Exercice 20 (Maximisation de la variance et droite la plus proche)

Cet exercice illustre le résultat théorique établi à l'exercice 13.

$$X = \begin{bmatrix} 1 & 1 \\ -1 & 0 \\ 0 & -1 \end{bmatrix},$$

Soit $w = \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}$ un vecteur unitaire ($\|w\| = 1$).

Nous cherchons à trouver la direction w qui maximise la variance de la projection de X sur w . Suivons ces étapes :

1. Combien de points de données y a-t-il dans le jeu de données X ? Le jeu de données est-il centré ?
2. Expliquer pourquoi maximiser la variance de Xw revient à minimiser la distance entre les points de données et leurs projections sur la droite engendrée par w .

3. Expression de la variance de la projection

Montrer que la variance des données projetées Xw est :

$$\text{Var}(Xw) = w^T X^T X w.$$

4. Calculer $X^T X$.
5. En utilisant les résultats du précédent exercice, déterminer la direction w qui maximise la variance de la projection.
6. Tracer les points $(1; 1)$, $(-1; 0)$ et $(0; -1)$ sur un graphe et tracer la droite qui leur est la plus proche.

Exercice 21

On observe $p = 2$ variables sur $n = 5$ individus uniformément pondérés :

x_1	x_2
3	-2
3	2
0	-1
4	-3
0	-1

1. Déterminer la matrice de covariance S .
2. Diagonaliser la matrice S .
3. Déterminer la matrice C des composantes principales.

Exercice 22

On observe $p = 2$ variables sur $n = 4$ individus de même poids :

	x	y
a	2	2
b	-2	-2
c	-1	1
d	1	-1

1. Représenter les individus a, b, c, d dans le plan (x, y) .
2. Calculer la matrice de covariance S associée aux observations en utilisant la formule matricielle.
3. Diagonaliser la matrice S .
4. Faire apparaître les vecteurs propres sur le graphique de la question 1.
5. Calculer la matrice C des composantes principales et faire le lien avec le graphique.

Exercice 23

Au mois de novembre 2012, les services météorologiques ont relevé les précipitations p (en cm), la température maximale $t_{\max}$ (en °C) et la température minimale $t_{\min}$ (en °C) dans différentes villes de France. Voici les résultats obtenus pour six villes uniformément pondérées :

Ville	p	$t_{\max}$	$t_{\min}$
Ajaccio	12.04	23.7	5.9
Brest	17.18	15.5	-1.8
Dunkerque	11.83	13.1	2.8
Nancy	6.23	13.5	-2.4
Nice	16.99	21.1	7.2
Toulouse	3.87	20.3	-0.91

1. Calculer les moyennes de p , $t_{\max}$ et $t_{\min}$, puis donner la matrice X des données centrées.
2. Calculer la matrice de covariance Σ .
3. Un logiciel statistique fournit les matrices D et P telles que $\Sigma = PDP^T$:

$$D = \begin{pmatrix} 32.71 & 0 & 0 \\ 0 & 18.57 & 0 \\ 0 & 0 & 3.94 \end{pmatrix}, \quad P = \begin{pmatrix} 0.73 & 0.62 & 0.29 \\ 0.40 & -0.73 & 0.56 \\ 0.56 & -0.29 & -0.78 \end{pmatrix}.$$

- (a) Quelles sont les valeurs propres de Σ ?
- (b) Expliquer pourquoi la matrice P est inversible et pourquoi $P^{-1} = P^\top$.
4. Calculer la matrice des composantes principales C et représenter les villes dans le plan principal.
5. Calculer les corrélations linéaires entre les variables initiales et les deux premières composantes principales, puis représenter le cercle des corrélations.
6. Interpréter la position des villes dans le plan principal et commenter.

Exercice 24 (Variance)

Étant donné les valeurs singulières $(\sigma_1, \dots, \sigma_p)$ d'une matrice de données centrée X , on définit la proportion de variance représentée :

$$r_k = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^p \sigma_i^2}.$$

1. Montrer que r_k représente la proportion de la variance totale capturée par les k premières composantes principales.
2. Pour un jeu de données explicité, tracer r_k comme une fonction de k .
3. Comment choisiriez-vous k en pratique?

3 Projections et interprétation géométrique**Exercice 25** (Projecteur et idempotence)

Soit P un endomorphisme de $\mathbb{R}^p$ tel que $P^2 = P$.

1. Montrer que P est un projecteur sur $\text{Im}(P)$ parallèlement à $\ker(P)$.
2. En déduire que les valeurs propres de P sont 0 ou 1.
3. Donner un exemple de matrice de projection orthogonale et de projection oblique.

Exercice 26 (Propriétés d'une matrice de projection)

Soit $P = UU^\top$ où $U \in \mathcal{M}_{p,k}(\mathbb{R})$ a des colonnes orthonormées ($U^\top U = I_k$).

1. Prouver que P est symétrique et idempotent ($P^2 = P$).
2. Déterminer les valeurs propres de P .
3. Montrer que $\text{rg}(P) = k$.
4. Interpréter géométriquement ce que fait P sur tout vecteur $x \in \mathbb{R}^p$.

(★) Exercice 27 (Matrice de Gram)

Soient $p, q \in \mathbb{N}^*$. Soit $U = (u_1, \dots, u_q)$ une famille de vecteurs de $\mathbb{R}^p$. On appelle **matrice de Gram** associée à U la matrice définie par

$$G_U = U^\top U.$$

1. Montrer que G_U est une matrice symétrique définie positive.
2. Montrer que

$$G_U \in \text{GL}_q(\mathbb{R}) \iff \left(\forall \alpha_1, \dots, \alpha_q \in \mathbb{R}, \sum_{i=1}^q \alpha_i u_i = 0 \implies \forall i \in \llbracket 1, q \rrbracket, \alpha_i = 0 \right).$$

3. On suppose que $\text{rg}(U) = q$. Montrer que la matrice de la projection orthogonale sur $\text{Vect}(U)$ est donnée par

$$P = U (G_U)^{-1} U^\top.$$

4. On suppose que $\text{rg}(U) = q$. Pour tout $x \in \mathbb{R}^p$, on note $p(x)$ la projection orthogonale de x sur $\text{Vect}(U)$ et on note également $U' = (x, u_1, \dots, u_q)$.

- a) Montrer que

$$\det(G_{U'}) = \|x - p(x)\|^2 \det(G_U).$$

- b) En déduire que

$$d(x, \text{Vect}(U)) = \sqrt{\frac{\det(G_{U'})}{\det(G_U)}}.$$

5. Considérons désormais $\mathcal{F} = (u_1, u_2)$ la famille de vecteurs de $\mathbb{R}^4$ définie par

$$u_1 = \begin{pmatrix} 1 \\ -1 \\ 2 \\ 0 \end{pmatrix}, \quad u_2 = \begin{pmatrix} 1 \\ 0 \\ -1 \\ 1 \end{pmatrix}.$$

- a) Déterminer la matrice de Gram associée.
 b) En déduire la matrice de la projection orthogonale sur $\text{Vect}(\mathcal{F})$.
 c) Déterminer $d(x, \text{Vect}(\mathcal{F}))$, où x est un vecteur quelconque de $\mathbb{R}^4$.

(★) **Exercice 28** (Matrice de Householder)

Soit $U = \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} \in \mathbb{R}^{n \times 1}$ tel que $\sum_{i=1}^n u_i^2 = 1$. On considère la matrice

$$A = I_n - 2UU^\top.$$

- Montrer que A est symétrique.
- Calculer A^2 .
- En déduire les valeurs propres de A .
- Montrer que $\text{Vect}(U)$ et son orthogonal $\text{Vect}(U)^\perp$ sont les sous-espaces propres associés.
- Interpréter géométriquement l'application linéaire $x \mapsto Ax$: de quelle transformation orthogonale s'agit-il ?
- (Facultatif) Montrer que A est une matrice orthogonale de déterminant -1 .
- (Ouverture) Exprimer A sous la forme $A = I_n - 2P$, où P est un projecteur orthogonal, et relier cette écriture à la notion de symétrie orthogonale par rapport à un hyperplan.

(★) **Exercice 29** (Décomposition de l'inertie)

Soit $M = \{x_1, \dots, x_n\}$ un nuage de points de centre $g = 0$. On note P_W la projection orthogonale sur un sous-espace W .

1. Montrer que l'inertie totale se décompose en

$$I_T(M) = I_W(M) + I_{W^\perp}(M).$$

2. En déduire que l'axe principal de M est celui qui maximise $I_W(M)$, autrement dit celui de variance maximale.

(★) **Exercice 30** (ACP à partir de distances)

On considère un nuage de n points dont on ne connaît que les distances $d_{ii'}^2$. Montrer que l'on peut reconstituer une matrice de Gram G vérifiant

$$G_{ii'} = -\frac{1}{2} \left(d_{ii'}^2 - d_{i.}^2 - d_{.i'}^2 + d_{..}^2 \right),$$

où $d_{i.}$ et $d_{.i'}$ désignent les moyennes des distances. En déduire comment effectuer une ACP sans connaître les coordonnées originales.

4 Comprendre le machine learning

Exercice 31

Expliquer comment la « somme des carrés » est utilisée comme fonction objectif dans les situations suivantes :

- Régression linéaire
- Clustering
- Analyse en composantes principales (ACP)

(★) **Exercice 32** (Quotient de Rayleigh et plus grande valeur propre)

Soit $A \in \mathbb{R}^{n \times n}$ symétrique. Montrer que

$$\lambda_{\max}(A) = \max_{\|x\|_2=1} x^\top A x = \max_{x \neq 0} \frac{x^\top A x}{x^\top x}.$$

Interpréter géométriquement cette égalité dans le cas où A est la matrice de covariance d'un jeu de données centré.

Exercice 33

 (Deux définitions équivalentes de ACP)

Soit $X \in \mathbb{R}^{n \times p}$ un jeu de données centré.

1. Montrer que la première direction principale u_1 maximise la variance des projections :

$$u_1 = \arg \max_{\|u\|_2=1} \text{Var}(Xu) = \arg \max_{\|u\|_2=1} u^\top X^\top X u.$$

2. Soit U_k la matrice des k premières directions principales. Montrer que U_k minimise également l'erreur de reconstruction :

$$U_k = \arg \min_{U^\top U = I_k} \|X - XU U^\top\|_F^2.$$

3. Interpréter géométriquement pourquoi les critères “variance maximale” et “erreur de reconstruction minimale” conduisent au même sous-espace.

Exercice 34

 (norme de Frobenius et valeurs singulières)

Soit $A = U \Sigma V^\top$ la décomposition en valeurs singulières de $A \in \mathbb{R}^{m \times n}$.

1. Montrer que

$$\|A\|_F^2 = \sum_i \sigma_i^2.$$

2. Montrer que, parmi toutes les matrices de rang k , celle qui minimise $\|A - B\|_F$ est

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^\top.$$

3. Interpréter ce résultat en termes d'énergie conservée et expliquer son lien avec l'ACP.

(★) **Exercice 35** (ACP et autoautoencodeur linéaire)

Soit $X \in \mathbb{R}^{n \times p}$ une matrice de données centrée (chaque ligne correspond à une observation et chaque colonne à une variable).

1. Formulation ACP

Rappeler que les composantes principales peuvent être obtenues en résolvant

$$\min_{W_k^\top W_k = I_k} \|X - XW_k W_k^\top\|_F^2.$$

Prouver que le W_k optimal est formé par les vecteurs propres de $X^\top X$ associés aux k plus grandes valeurs propres.

2. Autoautoencodeur linéaire

Considérons un réseau de neurones avec une couche cachée de dimension k et des fonctions d'activation linéaires :

$$h = W_1 x, \quad \hat{x} = W_2 h = W_2 W_1 x,$$

où $W_1 \in \mathbb{R}^{k \times p}$ et $W_2 \in \mathbb{R}^{p \times k}$.

Le modèle est entraîné afin de minimiser l'erreur de reconstruction

$$L(W_1, W_2) = \|X - XW_1^\top W_2^\top\|_F^2.$$

Montrer que toute paire (W_1, W_2) minimisant cette fonction de perte engendre le même sous-espace que les k composantes principales de l'ACP.

3. Application numérique (optional).

Via Python (NumPy, `scikit-learn`, ou `tensorflow.keras`), vérifier cette équivalence :

- (a) Entraîner un autoencodeur linéaire avec une couche cachée de dimension $k = 2$ sur un jeu de données centré (par exemple `Iris` ou un jeu de données synthétique).
- (b) Déterminer les deux premières composantes principales de X via l'ACP.
- (c) Comparer les sous-espaces engendrés par les colonnes de $W_1^\top$ et par les composantes de l'ACP (ils devraient coïncider à une rotation et une mise à l'échelle près).

4. Discussion

Expliquer comment des fonctions d'activations non linéaires (par exemple ReLU, sigmoïde) augmentent la capacité de représentation d'un autoencodeur par rapport à la PCA. Dans quel sens l'ACP peut-elle être considérée comme le « cas linéaire » d'un autoencodeur ?

N.B. Vous pouvez utiliser la décomposition en valeurs singulières $X = U\Sigma V^\top$ pour montrer que la projection ACP et la reconstruction de l'autoautoencodeur linéaire sont également égaux à $XV_k V_k^\top$ pour un certain k .

(★) **Exercice 36** (Problème de Procuste orthogonal)

Étant données deux matrices $A, B \in \mathbb{R}^{n \times p}$, considérons

$$\min_{R \in O(p)} \|A - BR\|_F^2.$$

1. Montrer que le R optimal est $R^* = UV^\top$ où $U\Sigma V^\top$ est la SVD de $B^\top A$.
2. Interpréter géométriquement : R^* est la transformation orthogonale qui aligne au mieux B sur A .

(★) **Exercice 37** (Conditionnement et sensibilité)

Soit $A \in \mathbb{R}^{n \times n}$ inversible et $b \in \mathbb{R}^n$. Nous résolvons $Ax = b$.

1. Montrer que $\|A^{-1}\|_2 = 1/\sigma_{\min}(A)$.
2. Définir le conditionnement $\kappa(A) = \|A\|_2\|A^{-1}\|_2 = \sigma_{\max}(A)/\sigma_{\min}(A)$.
3. Expliquer géométriquement ce qui arrive à l'image de la sphère unité lorsque $\kappa(A)$ est grande.
4. Interpréter cela en termes d'instabilité numérique et de gradients qui disparaissent ou explosent dans les réseaux profonds.

5 Distances généralisées et métriques adaptées

Exercice 38 (Définition et calcul direct de la distance de Mahalanobis)

Soit un jeu de données centré $X \in \mathbb{R}^{n \times p}$ (chaque ligne un individu, chaque colonne une variable). On note $\Sigma = \frac{1}{n-1}X^\top X$ la matrice de covariance (supposée inversible).

1. Pour un individu $x_i \in \mathbb{R}^p$, écrire la formule de la distance de Mahalanobis entre x_i et la moyenne (qui est le vecteur nul dans ce cas).

$$d_M(x_i) = \sqrt{x_i^\top \Sigma^{-1} x_i}.$$

2. Soit $p = 2$ et les deux variables suivantes sur 4 individus :

$$\begin{pmatrix} 2 & 3 \\ 4 & 6 \\ -1 & -1 \\ 1 & 2 \end{pmatrix}$$

Calculer explicitement Σ , Σ^{-1} puis les distances de Mahalanobis des 4 individus.

3. Comparer ces distances avec la distance euclidienne standard (centrée) des mêmes individus. Que constatez-vous ? Expliquer le rôle de la covariance dans l'ajustement de la distance.

Exercice 39 (Interprétation géométrique et lien avec l'ACP)

Soit $X \in \mathbb{R}^{n \times p}$ centré, $\Sigma = \frac{1}{n-1}X^\top X$.

1. En utilisant la décomposition spectrale $\Sigma = V\Lambda V^\top$, montrer que

$$d_M(x) = \sqrt{(V^\top x)^\top \Lambda^{-1} (V^\top x)}.$$

Interpréter cette expression : que fait $V^\top$, que fait Λ^{-1} ?

2. Mettre en relation cette interprétation avec l'ACP (axes principaux).
3. Montrer que la surface $\{x : d_M(x) = c\}$ est une « ellipsoïde centré », dont les directions principales sont les vecteurs propres de Σ et dont les longueurs d'axes sont proportionnelles aux racines inverses des valeurs propres.

Exercice 40 (Application à la détection de valeurs aberrantes)

On considère un jeu de données centré $X \in \mathbb{R}^{n \times p}$. Pour chaque observation x_i , on calcule la distance de Mahalanobis $d_M(x_i)$.

1. Supposons que les observations proviennent d'une loi normale multivariée $\mathcal{N}(0, \Sigma)$. Montrer que $d_M(x_i)^2$ suit une loi χ_p^2 (à p degrés de liberté).
2. Proposer une règle de détection d'outliers basée sur $d_M(x_i)$ et un seuil correspondant à un quantile de la χ_p^2 .
3. Sur un petit exemple (par ex. $p = 2$, 6 individus), calculer d_M et appliquer la règle. Discuter les résultats.

Exercice 41 [Distance de Mahalanobis et détection de valeurs aberrantes]

On considère un échantillon de vecteurs aléatoires

$$X = (x_1, \dots, x_n)^\top \in \mathbb{R}^{n \times p},$$

supposé centré, c'est-à-dire

$$\frac{1}{n} \sum_{i=1}^n x_i = 0.$$

On note $\Sigma \in \mathbb{R}^{p \times p}$ la matrice de covariance (supposée définie positive). Pour toute observation x_i , on définit la distance de Mahalanobis

$$d_M(x_i) = \sqrt{x_i^\top \Sigma^{-1} x_i}.$$

1. On suppose que les observations proviennent d'une loi normale multivariée

$$x_i \sim \mathcal{N}(0, \Sigma).$$

Montrer que la variable aléatoire $d_M(x_i)^2$ suit une loi du χ^2 à p degrés de liberté.

2. On souhaite identifier des valeurs aberrantes au sein des observations. Proposer une règle de décision fondée sur $d_M(x_i)$: spécifier un seuil basé sur un quantile d'ordre $1 - \alpha$ de la loi χ_p^2 , et formuler un critère permettant de déclarer x_i aberrant.
3. Construire un petit exemple numérique pour $p = 2$ avec $n = 6$.
 - Choisir explicitement les six observations et une matrice de covariance.
 - Calculer $d_M(x_i)$ pour chaque individu.
 - Appliquer la règle de détection de la question précédente.
 - Interpréter les résultats obtenus.

Exercice 42

On considère un vecteur aléatoire $X = (X_1, X_2)^T$ de moyenne nulle et de matrice de covariance

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix}.$$

1. Calculer la distance de Mahalanobis entre deux points x et y de $\mathbb{R}^2$:

$$d_M(x, y) = \sqrt{(x - y)^T \Sigma^{-1} (x - y)}.$$

2. Déterminer la matrice de whitening W telle que $W \Sigma W^T = I$.
3. Montrer que la transformation $z = Wx$ transforme la distance de Mahalanobis en distance euclidienne :

$$d_M(x, y) = \|W(x - y)\|_2.$$

4. Vérifier numériquement, pour $x = (2, 0)^T$ et $y = (0, 1)^T$, que $d_M(x, y)$ coïncide avec la norme euclidienne de $W(x - y)$.

5. Interpréter géométriquement la matrice W : que fait-elle aux ellipses de covariance associées à Σ ?

Indications : La diagonalisation de Σ donne

$$\Sigma = U\Lambda U^T, \quad U = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 & -1 \\ 1 & 2 \end{bmatrix}, \quad \Lambda = \begin{bmatrix} 5 & 0 \\ 0 & 1 \end{bmatrix}.$$

On en déduit

$$W = \Lambda^{-1/2} U^T.$$

Résultat attendu :

$$W = \frac{1}{\sqrt{5}} \begin{bmatrix} \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \\ -\frac{1}{2} & 1 \end{bmatrix} \quad \text{et} \quad d_M(x, y) = \|W(x - y)\|_2.$$

Interprétation : Le whitening “sphérise” la métrique : les ellipses de covariance de Σ deviennent des cercles, et la distance de Mahalanobis devient la norme euclidienne dans cet espace transformé.

6 Optionnel

(★) **Exercice 43** (Produit de Kronecker – calcul et propriétés)

Soient $A \in \mathbb{R}^{m \times n}$ et $B \in \mathbb{R}^{p \times q}$. On définit le produit de Kronecker

$$A \otimes B \in \mathbb{R}^{(mp) \times (nq)}$$

par blocs : le bloc de taille $p \times q$ de la ligne-bloc i , colonne-bloc j vaut $a_{ij} B$.

1. Donner un exemple numérique simple ($m=2, n=2$; $p=2, q=2$) de deux matrices et calculer explicitement leur $A \otimes B$.
2. Montrer la propriété de vectorisation : pour $X \in \mathbb{R}^{n \times p}$,

$$\text{vec}(AXB) = (B^\top \otimes A) \text{vec}(X).$$

(où $\text{vec}(X)$ est le vecteur obtenu en empilant les colonnes de X).

3. Donner une interprétation (en termes de transformations linéaires) du produit de Kronecker : si A représente une application linéaire sur $\mathbb{R}^n$ et B sur $\mathbb{R}^q$, que représente $A \otimes B$ sur $\mathbb{R}^{nq}$?

(★) **Exercice 44** (Produit de Khatri–Rao – définition et usage)

Soient $A \in \mathbb{R}^{m \times N}$ et $B \in \mathbb{R}^{p \times N}$. Le produit de Khatri–Rao $A * B \in \mathbb{R}^{(mp) \times N}$ est défini colonne-par-colonne : pour la colonne j , la j -ième colonne de $A * B$ est $a_{:,j} \otimes b_{:,j}$.

1. Écrire formellement cette définition et donner un petit exemple numérique ($m=2, p=2, N=3$) pour illustrer.
2. Montrer que ce produit peut être vu comme un « Kronecker appliqué colonne par colonne » et comparer le rang potentiel de $A * B$ avec les rangs de A et B .
3. Discuter un contexte où ce produit peut être utile (par exemple : modélisation factorielle, algèbre tensorielle simplifiée, ou représentation de modèles à variables multiples).

(★) **Exercice 45** (Application — factorisation tensorielle simplifiée)

Dans un modèle de données multi-way (par exemple observations $\times$ variables $\times$ conditions), on peut « déplier » le tenseur et obtenir une matrice que l’on factorise. Le produit de Kronecker ou Khatri–Rao permet d’exprimer certaines de ces factorisations.

1. Supposons que l'on a deux matrices $W \in \mathbb{R}^{n \times r}$ et $H \in \mathbb{R}^{m \times r}$ et que l'on souhaite modéliser une matrice $X \in \mathbb{R}^{nm \times r}$ via $X \approx W * H$ (produit de Khatri–Rao). Écrire cette approximation et dites ce que cela signifie en termes de colonnes de X .
2. Montrer comment, en utilisant le produit de Kronecker, on peut écrire une forme linéaire ou bilinéaire plus large $Y = (W \otimes H)Z$, et expliquer la différence entre cette forme et le produit de Khatri–Rao.
3. Envisager l'utilité dans un algorithme de réduction de dimension ou de modélisation de données structurées. Comment cet outil relie-t-il la théorie de l'algèbre linéaire à des applications modernes ?