

PROBABILITÉS IV – COURS

Table des matières

1	Quelques rappels fondamentaux	2
2	Convergence de suites de variables aléatoires	4
2.1	Quelques théorèmes fondamentaux	7
2.2	Point méthode fondamental	8
3	Couple de variables aléatoires	9
3.1	Loi jointe et lois marginales	9
3.2	Quantifier la dépendance linéaire	10
4	Conditionnement de variables aléatoires	12
4.1	Probabilité conditionnelle	12
4.2	Loi conditionnelle	13
4.3	Espérance conditionnelle	14
5	Vecteurs gaussiens	17

Dans l'intégralité de ce cours, on se place dans un espace probabilisé $(\Omega, \mathcal{A}, \mathbb{P})$ et on suppose que toutes les variables aléatoires introduites par la suite sont définies sur cet espace probabilisé.

1 Quelques rappels fondamentaux

Définition :

Soit $A \subset \mathbb{R}$. On appelle **fonction indicatrice de A** la fonction définie par

$$\begin{aligned} \mathbb{1}_A &: \mathbb{R} \longrightarrow \{0, 1\} \\ \omega &\longmapsto \begin{cases} 1 & \text{si } \omega \in A \\ 0 & \text{si } \omega \notin A \end{cases} \end{aligned}$$

Proposition :

Soit $A \in \mathcal{A}$. On a

$$\boxed{\mathbb{E}(\mathbb{1}_A) = \mathbb{P}(A)}.$$

Preuve :

Soit $A \in \mathcal{A}$. On a

$$\begin{aligned} \mathbb{E}(\mathbb{1}_A) &= \sum_{k \in \{0,1\}} k \mathbb{P}(\mathbb{1}_A = k) & (\mathbb{1}_A(\Omega) = \{0, 1\}) \\ &= 0 \cdot \mathbb{P}(\mathbb{1}_A = 0) + 1 \cdot \mathbb{P}(\mathbb{1}_A = 1) \\ &= \mathbb{P}(\mathbb{1}_A = 1) \\ &= \mathbb{P}(A) & (\forall \omega \in \Omega, \mathbb{1}_A(\omega) = 1 \iff \omega \in A) \end{aligned}$$

Définition :

Soit X une variable aléatoire discrète (resp. continue de densité f_X). On définit l'**espérance** de X par

$$\boxed{\mathbb{E}(X) = \sum_{k \in X(\Omega)} k \mathbb{P}(X = k)} \quad \left(\text{resp. } \boxed{\mathbb{E}(X) = \int_{\mathbb{R}} t f_X(t) dt} \right).$$

L'espérance mesure ainsi la valeur moyenne que l'on peut attendre de X si l'on répète une expérience aléatoire un grand nombre de fois : il s'agit de la moyenne théorique de X .

De façon plus générale, on appelle **moment d'ordre $r \in \mathbb{N}^*$** le réel défini par

$$\boxed{\mathbb{E}(X^r) = \sum_{k \in X(\Omega)} k^r \mathbb{P}(X = k)} \quad \left(\text{resp. } \boxed{\mathbb{E}(X^r) = \int_{\mathbb{R}} t^r f_X(t) dt} \right).$$

lorsqu'il existe, i.e. lorsque $\mathbb{E}(|X^r|) < \infty$. Si ce moment existe, on notera $X \in L^r(\Omega)$.

Inégalité de Markov :

Soit $X \in L^1(\Omega)$ positive. Alors

$$\forall a > 0, \quad \boxed{\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}}.$$

Preuve :

Soit $a > 0$. Constatons que

$$X \geq a \mathbb{1}_{\{X \geq a\}}.$$

Effectivement, pour tout $\omega \in \Omega$,

- Si $0 \leq X(\omega) < a$ il suffit de constater que $0 = a \times 0 = a \mathbb{1}_{\{X \geq a\}}(\omega)$.
- Si $X(\omega) \geq a$ il suffit de constater que $a = a \times 1 = a \mathbb{1}_{\{X \geq a\}}(\omega)$.

En particulier, on a

$$\begin{aligned}\mathbb{E}[X] &\geq a \mathbb{E}[\mathbb{1}_{\{X \geq a\}}] \\ &= a \mathbb{P}(X \geq a).\end{aligned}$$

Inégalité de Bienaymé-Tchebychev :

Soit $X \in L^2(\Omega)$. Alors

$$\forall \varepsilon > 0, \quad \mathbb{P}(|X - \mathbb{E}[X]| \geq \varepsilon) \leq \frac{\mathbb{V}(X)}{\varepsilon^2}.$$

Preuve :

Soit $\varepsilon > 0$. On a

$$\begin{aligned}\mathbb{P}(|X - \mathbb{E}[X]| \geq \varepsilon) &= \mathbb{P}((X - \mathbb{E}[X])^2 \geq \varepsilon^2) \quad (\forall x, y \in \mathbb{R}_+, x \geq y \iff x^2 \geq y^2) \\ &\leq \frac{\mathbb{E}[(X - \mathbb{E}[X])^2]}{\varepsilon^2} \quad (\text{Markov appliqué en la variable aléatoire positive } (X - \mathbb{E}[X])^2) \\ &= \frac{\mathbb{V}(X)}{\varepsilon^2} \quad (\text{Définition de } \mathbb{V}(X))\end{aligned}$$

Proposition :

On a

$$\forall \alpha \in \mathbb{R}, \quad \lim_{n \rightarrow \infty} \left(1 + \frac{\alpha}{n}\right)^n = e^\alpha.$$

Preuve :

Soit $\alpha \in \mathbb{R}$ et $n \in \mathbb{N}$. On a

$$\left(1 + \frac{\alpha}{n}\right)^n = \exp\left(n \ln\left(1 + \frac{\alpha}{n}\right)\right).$$

Or,

$$\begin{aligned}\lim_{n \rightarrow \infty} n \ln\left(1 + \frac{\alpha}{n}\right) &= \lim_{n \rightarrow \infty} \frac{\ln\left(1 + \frac{\alpha}{n}\right)}{\frac{1}{n}} \\ &= \lim_{h \rightarrow 0} \frac{\ln(1 + \alpha h)}{h} \\ &= \lim_{h \rightarrow 0} \frac{\ln(1 + \alpha(0 + h)) - \ln(1 + \alpha \cdot 0)}{h}\end{aligned}$$

On reconnaît la limite de taux d'accroissement de la fonction $f : x \mapsto \ln(1 + \alpha x)$ en $x = 0$. Ainsi,

$$\begin{aligned}\lim_{n \rightarrow \infty} n \ln\left(1 + \frac{\alpha}{n}\right) &= f'(0) \\ &= \frac{\alpha}{1 + \alpha \cdot 0} \\ &= \alpha.\end{aligned}$$

Par conséquent, en vertu de la continuité de $\exp$,

$$\lim_{n \rightarrow \infty} \left(1 + \frac{\alpha}{n}\right)^n = e^\alpha$$

2 Convergence de suites de variables aléatoires

L'objectif de cette section est d'étudier le comportement asymptotique de suites de variables aléatoires, en introduisant différentes notions de convergence et en développant des outils fondamentaux permettant de les analyser.

Il existe de nombreuses notions de convergence de variables aléatoires. Elles servent surtout à montrer que les phénomènes aléatoires présentent certaines régularités, à partir desquelles on peut identifier certaines de leurs propriétés.

Dans l'intégralité de cette section, on considère $X \in L(\Omega)$ et $(X_n)_{n \geq 1}$ une suite de variables aléatoires définies sur Ω .

Définition :

Notons $F_X : t \mapsto \mathbb{P}(X \leq t)$ la fonction de répartition de X .

- On dit que $(X_n)_{n \geq 1}$ **converge en loi** vers X lorsque

$$F_{X_n} \xrightarrow{n \rightarrow \infty} F_X \text{ en tout point où } F_X \text{ est continue.}$$

Auquel cas, on note $X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X$.

- On dit que $(X_n)_{n \geq 1}$ **converge en probabilité** vers X lorsque

$$\forall \varepsilon > 0, \mathbb{P}(|X_n - X| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0.$$

Auquel cas, on note $X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} X$.

- On dit que $(X_n)_{n \geq 1}$ **converge presque sûrement** vers X lorsque

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1.$$

Auquel cas, on note $X_n \xrightarrow[n \rightarrow \infty]{\text{p.s.}} X$.

Remarque fondamentale :

Intuitivement, la convergence presque sûre est plus forte que la convergence en probabilité, elle-même plus forte que la convergence en loi. En lisant les définitions de près, on comprend pourquoi cette hiérarchie est naturelle :

- La convergence en loi est la plus faible des trois : elle n'affirme rien sur les valeurs prises par X_n et X simultanément, seulement qu'à mesure que n grandit, leurs fonctions de répartition coïncident.

C'est une convergence portant sur la distribution de X_n , et non sur X_n elle-même.

- La convergence en probabilité signifie qu'à mesure que n grandit, il devient de moins en moins probable que X_n s'écarte significativement de X . Elle contrôle ainsi la fréquence probabiliste des déviations sans rien garantir sur leur comportement simultané pour tout événement ω .
- La convergence presque sûre affirme que l'événement

$$\left\{ \lim_{n \rightarrow \infty} X_n = X \right\}$$

est de probabilité 1. Autrement dit, excepté sur un ensemble de probabilité nulle, $(X_n(\omega))_{n \geq 1}$ converge vers $X(\omega)$ pour tout ω . Il s'agit d'une convergence événement par événement.

La convergence en probabilité contrôle ainsi globalement la fréquence des déviations, tandis que la convergence presque sûre assure un contrôle individuel pour presque tout événement ω .

Exemple :

Considérons $X \sim \mathcal{N}(0, 1)$ et

$$\forall n \geq 1, X_n = (-1)^n X.$$

Alors X_n converge en loi vers X car $F_{X_n} = F_X$ pour tout $n \in \mathbb{N}$ par symétrie de la loi normale centrée réduite, cependant X_n ne converge ni presque sûrement, ni en probabilité vers X en raison des termes impairs de $(X_n)_{n \geq 1}$.

Théorème de convergence dominée – Admis :

Supposons que :

- $X_n \xrightarrow[n \rightarrow \infty]{\text{p.s.}} X$,

- Pour tout $n \geq 1$, il existe $Z \in L^1(\Omega)$ telle que $|X_n| \leq Z$ presque sûrement (i.e. excepté sur un ensemble de probabilité nulle, aussi appelé ensemble négligeable).

Alors $X \in L^1(\Omega)$ et

$$\mathbb{E}[X_n] \xrightarrow{n \rightarrow \infty} \mathbb{E}[X].$$

Proposition :

On a

$$X_n \xrightarrow[n \rightarrow \infty]{\text{p.s.}} X \implies X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} X \implies X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X.$$

Preuve :

Première implication : Soit $\varepsilon > 0$. Considérons, pour tout $n \geq 1$, l'évènement défini par

$$A_n = \{|X_n - X| > \varepsilon\}.$$

On a

$$\begin{aligned} X_n \xrightarrow[n \rightarrow \infty]{\text{p.s.}} X &\iff \mathbb{P}\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1 \\ &\iff \mathbb{P}\left(\lim_{n \rightarrow \infty} |X_n - X| = 0\right) = 1. \end{aligned}$$

Ainsi, pour presque tout $\omega \in \Omega$,

$$\begin{aligned} &\exists N_\omega \in \mathbb{N}, \forall n \geq N_\omega, |X_n(\omega) - X(\omega)| \leq \varepsilon \\ &\iff \exists N_\omega \in \mathbb{N}, \forall n \geq N_\omega, \omega \notin A_n \\ &\iff \exists N_\omega \in \mathbb{N}, \forall n \geq N_\omega, \mathbb{1}_{A_n}(\omega) = 0. \end{aligned}$$

Nécessairement,

$$\mathbb{1}_{A_n}(\omega) \xrightarrow[n \rightarrow \infty]{\text{p.s.}} 0.$$

Puisque $\mathbb{1}_{A_n}$ tend presque sûrement vers 0 et que $|\mathbb{1}_{A_n}| \leq 1$, le théorème de convergence dominée assure que

$$\begin{aligned} \lim_{n \rightarrow \infty} \mathbb{P}(A_n) &= \lim_{n \rightarrow \infty} \mathbb{E}[\mathbb{1}_{A_n}] \\ &= \mathbb{E}\left[\lim_{n \rightarrow \infty} \mathbb{1}_{A_n}\right] \\ &= \mathbb{E}(0) \\ &= 0, \end{aligned}$$

ce qui permet de conclure quant à la convergence en probabilité.

Seconde implication : Soit $t \in \mathbb{R}$ un point en lequel F_X est continue et $\varepsilon > 0$.

Rappelons que, pour tout évènement A, B , on a

$$\begin{aligned} A &= A \cap \Omega \\ &= A \cap (B \cup \overline{B}) \\ &= (A \cap B) \cup (A \cap \overline{B}) \\ &\subset B \cup (A \cap \overline{B}). \end{aligned}$$

En particulier, pour tout évènement A, B ,

$$\boxed{\mathbb{P}(A) \leq \mathbb{P}(B) + \mathbb{P}(A \cap \overline{B})} \quad \text{et} \quad \boxed{\mathbb{P}(B) \geq \mathbb{P}(A) - \mathbb{P}(A \cap \overline{B})}.$$

Ainsi, la première inégalité appliquée en $A = \{X_n \leq t\}$ et $B = \{X \leq t + \varepsilon\}$ assure que

$$\begin{aligned} F_{X_n}(t) = \mathbb{P}(X_n \leq t) &\leq \mathbb{P}(X \leq t + \varepsilon) + \mathbb{P}(X_n \leq t \cap X > t + \varepsilon) \\ &\leq \mathbb{P}(X \leq t + \varepsilon) + \mathbb{P}(|X - X_n| > \varepsilon). \end{aligned}$$

De même, la seconde inégalité appliquée en $A = \{X \leq t - \varepsilon\}$ et $B = \{X_n \leq t\}$ assure que

$$F_{X_n}(t) = \mathbb{P}(X_n \leq t) \geq \mathbb{P}(X \leq t - \varepsilon) - \mathbb{P}(X_n \leq t \cap X > t + \varepsilon)$$

$$\geq \mathbb{P}(X \leq t - \varepsilon) - \mathbb{P}(|X - X_n| > \varepsilon).$$

Ainsi

$$F_X(t - \varepsilon) - \mathbb{P}(|X - X_n| > \varepsilon) \leq F_{X_n}(t) \leq F_X(t + \varepsilon) + \mathbb{P}(|X - X_n| > \varepsilon).$$

Étant donné que $X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} X$, on a, en faisant tendre n vers l'infini :

$$F_X(t - \varepsilon) \leq \lim_{n \rightarrow \infty} F_{X_n}(t) \leq F_X(t + \varepsilon).$$

En faisant tendre ε vers 0 et en invoquant la continuité de F_X en t , on obtient finalement

$$F_{X_n}(t) \xrightarrow[n \rightarrow \infty]{} F_X(t).$$

Proposition – stabilité par continuité :

Soit $f : \mathbb{R} \rightarrow \mathbb{R}$ une fonction continue. Alors :

- $X_n \xrightarrow[n \rightarrow \infty]{\text{p.s.}} X \implies f(X_n) \xrightarrow[n \rightarrow \infty]{\text{p.s.}} f(X).$
- $X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} X \implies f(X_n) \xrightarrow[n \rightarrow \infty]{\mathbb{P}} f(X).$
- $X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X \implies f(X_n) \xrightarrow[n \rightarrow \infty]{\mathcal{L}} f(X).$

Proposition – stabilité par addition & multiplication :

Si $(X_n)_{n \geq 1}$ et $(Y_n)_{n \geq 1}$ désignent deux suites de variables aléatoires et X, Y des variables aléatoires alors

- $X_n \xrightarrow[n \rightarrow \infty]{\text{p.s.}} X$ et $Y_n \xrightarrow[n \rightarrow \infty]{\text{p.s.}} Y \implies X_n + Y_n \xrightarrow[n \rightarrow \infty]{\text{p.s.}} X + Y$ et $X_n Y_n \xrightarrow[n \rightarrow \infty]{\text{p.s.}} XY.$
- $X_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} X$ et $Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} Y \implies X_n + Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} X + Y$ et $X_n Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} XY.$
- $X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X$ et $Y_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} Y$ et $(X_n, Y_n) \xrightarrow[n \rightarrow \infty]{\mathcal{L}} (X, Y) \implies X_n + Y_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X + Y$ et $X_n Y_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} XY.$

Proposition – Caractérisation de la convergence en loi dans le cas discret :

Supposons que X et $(X_n)_{n \geq 1}$ sont à valeurs dans $\mathbb{Z}$. Alors

$$X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X \iff \forall k \in \mathbb{Z}, \mathbb{P}(X_n = k) \xrightarrow[n \rightarrow \infty]{} \mathbb{P}(X = k).$$

Preuve :

Sens direct : Supposons que $X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X$. Soit $k \in X(\Omega)$.

Puisque X est à valeurs entières, F_X est constante sur les intervalles $]k - 1, k[$ et $]k, k + 1[$. En particulier :

$$F_{X_n}(k) = F_{X_n}\left(k + \frac{1}{2}\right) \quad \text{et} \quad F_{X_n}(k - 1) = F_{X_n}\left(k - \frac{1}{2}\right).$$

Puisque $k - \frac{1}{2}$ et $k + \frac{1}{2}$ ne sont pas des entiers, ils n'appartiennent pas à $X(\Omega)$, donc $\mathbb{P}(X = k \pm \frac{1}{2}) = 0$.

Autrement dit, F_X est continue en $k - \frac{1}{2}$ et en $k + \frac{1}{2}$. Par conséquent, la convergence en loi assure que

$$\begin{aligned} \mathbb{P}(X_n = k) &= F_{X_n}(k) - F_{X_n}(k - 1) \\ &= F_{X_n}\left(k + \frac{1}{2}\right) - F_{X_n}\left(k - \frac{1}{2}\right) \\ &\xrightarrow[n \rightarrow \infty]{} F_X(k) - F_X(k - 1) \\ &= \mathbb{P}(X = k). \end{aligned}$$

Sens réciproque : Supposons que

$$\forall k \in \mathbb{Z}, \mathbb{P}(X_n = k) \xrightarrow[n \rightarrow \infty]{} \mathbb{P}(X = k).$$

Soit $x \in \mathbb{R}$ un point de continuité de F_X , i.e. vérifiant $\mathbb{P}(X = x) = 0$. Puisque X est à valeurs entières, x n'est pas nécessairement un entier, et on a :

$$F_{X_n}(x) = \sum_{\substack{k \in \mathbb{Z} \\ k \leq x}} \mathbb{P}(X_n = k).$$

Le théorème de convergence dominée sur les séries permet d'intervertir limite et série :

$$F_{X_n}(x) = \sum_{\substack{k \in \mathbb{Z} \\ k \leq x}} \mathbb{P}(X_n = k) \xrightarrow{n \rightarrow \infty} \sum_{\substack{k \in \mathbb{Z} \\ k \leq x}} \mathbb{P}(X = k) = F_X(x).$$

Ceci étant valable pour tout point de continuité x de F_X , on conclut $X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X$.

Exemple :

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires telles que

$$X_n \sim \mathcal{B}\left(n, \frac{p}{n}\right), \quad \text{où } p > 0.$$

Soit $k \in \mathbb{N}$ et $n \geq k$. On a

$$\begin{aligned} \mathbb{P}(X_n = k) &= \binom{n}{k} \left(\frac{p}{n}\right)^k \left(1 - \frac{p}{n}\right)^{n-k} \\ &= \frac{n(n-1) \cdots (n-k+1)}{k!} \cdot \frac{p^k}{n^k} \cdot \left(1 - \frac{p}{n}\right)^n \left(1 - \frac{p}{n}\right)^{-k} \\ &= \frac{p^k}{k!} \cdot \frac{n(n-1) \cdots (n-k+1)}{n^k} \cdot \left(1 - \frac{p}{n}\right)^n \left(1 - \frac{p}{n}\right)^{-k}. \end{aligned}$$

Or,

$$\frac{n(n-1) \cdots (n-k+1)}{n^k} \xrightarrow{n \rightarrow \infty} 1 \quad \text{et} \quad \left(1 - \frac{p}{n}\right)^n \xrightarrow{n \rightarrow \infty} e^{-p} \quad \text{et} \quad \left(1 - \frac{p}{n}\right)^{-k} \xrightarrow{n \rightarrow \infty} 1.$$

Ainsi,

$$\forall k \in \mathbb{N}, \mathbb{P}(X_n = k) \xrightarrow{n \rightarrow \infty} \frac{p^k}{k!} e^{-p}.$$

On reconnaît la loi de Poisson de paramètre p , d'où

$$X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{P}(p).$$

2.1 Quelques théorèmes fondamentaux

Théorème central limite – Admis :

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires **indépendantes** suivant toutes la loi $\mathcal{L}(X)$ où $\mathbb{E}(X) = \mu$ et $\mathbb{V}(X) = \sigma^2$. Considérons

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Alors

$$\sqrt{n} \frac{\bar{X}_n - \mu}{\sigma} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} Z \sim \mathcal{N}(0, 1).$$

Théorème – Loi faible des grands nombres :

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires **indépendantes** suivant toutes la loi $\mathcal{L}(X)$. Alors

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} \mathbb{E}(X).$$

Théorème – Loi forte des grands nombres – Admis :

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires **indépendantes** suivant toutes la loi $\mathcal{L}(X)$. Alors

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} \mathbb{E}(X).$$

Autrement dit,

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mathbb{E}(X)\right) = 1.$$

Lemme – Borel-Cantelli :

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires et X une variable aléatoire. Si pour tout $\varepsilon > 0$,

$$\sum_{n=1}^{\infty} \mathbb{P}(|X_n - X| > \varepsilon) < \infty,$$

alors

$$X_n \xrightarrow[n \rightarrow \infty]{\text{p.s.}} X.$$

Preuve :

Soit $(A_n)_{n \geq 1}$ une suite d'événements. Considérons l'événement

$$\limsup A_n = \bigcap_{k \geq 1} \bigcup_{n \geq k} A_n.$$

On a

$$\begin{aligned} \omega \in \limsup A_n &\iff \forall k \geq 1, \exists n \geq k, \omega \in A_n \\ &\iff \{n \geq 1 \mid \omega \in A_n\} \text{ n'est pas majoré} \\ &\iff \{n \geq 1 \mid \omega \in A_n\} \text{ est infini.} \end{aligned}$$

Ainsi, dire que $\limsup A_n$ est réalisé est équivalent à dire qu'une infinité de A_n sont réalisés. Supposons alors que

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty.$$

Posons $B_k = \bigcup_{n \geq k} A_n$. La suite $(B_k)_{k \geq 1}$ est décroissante au sens de l'inclusion, donc par continuité décroissante de $\mathbb{P}$:

$$\mathbb{P}(\limsup A_n) = \mathbb{P}\left(\bigcap_{k \geq 1} B_k\right) = \lim_{k \rightarrow \infty} \mathbb{P}(B_k).$$

Or, par sigma-additivité de $\mathbb{P}$:

$$0 \leq \mathbb{P}\left(\bigcup_{n \geq k} A_n\right) \leq \sum_{n \geq k} \mathbb{P}(A_n) \xrightarrow[k \rightarrow \infty]{} 0. \quad (\text{Reste d'une série convergente})$$

Nécessairement,

$$\mathbb{P}(\limsup A_n) = 0.$$

Soit $\varepsilon > 0$. On pose en particulier $A_n = \{|X_n - X| > \varepsilon\}$. Par hypothèse, $\sum_{n \geq 1} \mathbb{P}(A_n) < \infty$, donc

$$\mathbb{P}\left(\limsup_n A_n\right) = 0,$$

c'est-à-dire que $\mathbb{P}(|X_n - X| > \varepsilon \text{ infiniment souvent}) = 0$. Ce résultat valant pour tout $\varepsilon > 0$, on conclut que

$$X_n \xrightarrow[n \rightarrow \infty]{\text{p.s.}} X.$$

2.2 Point méthode fondamental

Considérons $X \in L(\Omega)$ et $(X_n)_{n \geq 1}$ une suite de variables aléatoires définies sur Ω .

- Afin de démontrer que $(X_n)_{n \geq 1}$ converge presque sûrement vers X , on utilise généralement la loi forte des grands nombres ou le lemme de Borel-Cantelli.
- Afin de démontrer que $(X_n)_{n \geq 1}$ converge en probabilité vers X , on considère toujours $\varepsilon > 0$ arbitrairement petit. Effectivement, $\varepsilon \mapsto \mathbb{P}(|X_n - X| > \varepsilon)$ étant décroissante, il suffit de traiter le cas où ε est dans un voisinage de zéro, puis conclure par majoration.

On majore ensuite $\mathbb{P}(|X_n - X| > \varepsilon)$ via des inégalités de concentration comme l'inégalité de Markov, l'inégalité de Bienaymé-Tchebychev, etc.

- Afin de démontrer que $(X_n)_{n \geq 1}$ converge en loi vers X , on étudie le comportement asymptotique de F_{X_n} la fonction de répartition de X_n en considérant x un point où F_X la fonction de répartition de X est continue.

Lorsque X et $(X_n)_{n \geq 1}$ sont à valeurs dans $\mathbb{Z}$, la situation se simplifie considérablement en vertu de la proposition énoncée plus haut.

3 Couple de variables aléatoires

3.1 Loi jointe et lois marginales

Définition :

Soit $X, Y \in L(\Omega)$ deux variables aléatoires discrètes. On appelle **loi jointe de (X, Y)** la loi de probabilité définie par

$$\forall x \in X(\Omega), \forall y \in Y(\Omega), \mathbb{P}(X = x \cap Y = y)$$

Elle vérifie

$$\sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} \mathbb{P}(X = x \cap Y = y) = 1.$$

On appelle **lois marginales** de X et Y les lois définies par

$$\begin{aligned} \forall x \in X(\Omega), \mathbb{P}(X = x) &= \sum_{y \in Y(\Omega)} \mathbb{P}(X = x \cap Y = y), \\ \forall y \in Y(\Omega), \mathbb{P}(Y = y) &= \sum_{x \in X(\Omega)} \mathbb{P}(X = x \cap Y = y). \end{aligned}$$

Les variables X et Y sont dites **indépendantes** lorsque

$$\forall (x, y) \in X(\Omega) \times Y(\Omega), \mathbb{P}(X = x \cap Y = y) = \mathbb{P}(X = x)\mathbb{P}(Y = y).$$

Définition :

Soit $X, Y \in L(\Omega)$ deux variables aléatoires continues. On dit que (X, Y) admet une **densité jointe** s'il existe une fonction $f_{X,Y} : \mathbb{R}^2 \rightarrow \mathbb{R}_+$ telle que

$$\forall A \subset \mathbb{R}^2, \mathbb{P}((X, Y) \in A) = \iint_A f_{X,Y}(x, y) dx dy.$$

Elle vérifie

$$\iint_{\mathbb{R}^2} f_{X,Y}(x, y) dx dy = 1.$$

On appelle **densités marginales** de X et Y les fonctions définies par

$$\begin{aligned} \forall x \in \mathbb{R}, f_X(x) &= \int_{\mathbb{R}} f_{X,Y}(x, y) dy, \\ \forall y \in \mathbb{R}, f_Y(y) &= \int_{\mathbb{R}} f_{X,Y}(x, y) dx. \end{aligned}$$

Les variables X et Y sont dites **indépendantes** lorsque

$$\forall (x, y) \in \mathbb{R}^2, f_{X,Y}(x, y) = f_X(x) f_Y(y).$$

Proposition :

Soit $X, Y \in L^1(\Omega)$. Si X et Y sont indépendantes alors

$$\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y).$$

Preuve :

Soit $X, Y \in L^1(\Omega)$ deux variables aléatoires discrètes. On a

$$\begin{aligned} \mathbb{E}(XY) &= \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} xy \mathbb{P}(X = x \cap Y = y) \\ &= \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} xy \mathbb{P}(X = x) \mathbb{P}(Y = y) \\ &= \left(\sum_{x \in X(\Omega)} x \mathbb{P}(X = x) \right) \left(\sum_{y \in Y(\Omega)} y \mathbb{P}(Y = y) \right) \\ &= \mathbb{E}(X) \mathbb{E}(Y). \end{aligned}$$

On admet le résultat dans le cas où X, Y désignent des variables aléatoires continues.

3.2 Quantifier la dépendance linéaire

Définition :

Soit $X, Y \in L^2(\Omega)$. On appelle **covariance de X et Y** le réel défini par

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))].$$

Remarque :

La covariance mesure la tendance de deux variables aléatoires à varier ensemble. Lorsque les deux variables s'écartent simultanément de leurs moyennes dans le même sens, la covariance est positive ; lorsqu'elles s'écartent en sens opposés, elle est négative.

La covariance permet de quantifier la dépendance linéaire entre deux variables aléatoires. Elle ne détecte en revanche aucune relation non linéaire entre ces variables.

Proposition :

Soit $X, Y, Z \in L^2(\Omega)$ et $\lambda \in \mathbb{R}$. Les assertions suivantes sont vérifiées :

- 1) $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$.
- 2) $\text{Cov}(\lambda X + Y, Z) = \lambda \text{Cov}(X, Z) + \text{Cov}(Y, Z)$. *Bilinéarité de la covariance.*
- 3) $\text{Cov}(X, Y) = \text{Cov}(Y, X)$. *Symétrie de la covariance.*
- 4) $X \perp\!\!\!\perp Y \implies \text{Cov}(X, Y) = 0$.

Remarque :

La réciproque de la dernière propriété est généralement fautive : avoir $\text{Cov}(X, Y) = 0$ n'implique pas nécessairement que X et Y sont indépendantes. Si l'on considère $X \sim \mathcal{U}(\{-1, 1\})$, et $Y = X^2$. Alors $Y = 1$, et

$$\text{Cov}(X, Y) = \text{Cov}(X, 1) = 0,$$

mais Y dépend entièrement de X , donc X et Y ne sont pas indépendantes.

Proposition :

Soit $X, Y \in L^2(\Omega)$. On a :

- 1) $\text{Cov}(X, X) = \mathbb{V}(X)$.
- 2) $\mathbb{V}(X + Y) = \mathbb{V}(X) + \mathbb{V}(Y) + 2\text{Cov}(X, Y)$.

Proposition – Inégalités de Cauchy-Schwarz :

Soit $X, Y \in L^2(\Omega)$. On a :

- 1) $\mathbb{E}(XY) \leq \sqrt{\mathbb{E}(X^2)\mathbb{E}(Y^2)}$.
- 2) $|\text{Cov}(X, Y)| \leq \sqrt{\mathbb{V}(X)\mathbb{V}(Y)}$.

Définition :

Soit $X, Y \in L^2(\Omega)$. On définit le **coefficient de corrélation linéaire de X et Y** par


$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\mathbb{V}(X)\mathbb{V}(Y)}}$$

Remarque :

La seconde inégalité de Cauchy-Schwarz assure que $\rho(X, Y) \in [-1, 1]$. On effectue alors les interprétations suivantes :

- Si $\rho(X, Y)$ est proche de 0, les variables X et Y sont dites faiblement corrélées.
- Si $\rho(X, Y)$ est proche de 1, les variables X et Y sont dites fortement corrélées positivement.
- Si $\rho(X, Y)$ est proche de -1 , les variables X et Y sont dites fortement corrélées négativement.

ATTENTION : Il ne faut SURTOUT PAS confondre **corrélation** et **causalité**. Il y a par exemple une forte corrélation positive entre l'espérance de vie et la consommation annuelle de la viande, mais cela ne veut absolument pas dire que manger de la viande fait vivre plus longtemps !



Cette forte corrélation résulte uniquement du fait que les pays pauvres ont très peu accès à la viande et que l'espérance de vie dans ces pays est bien plus faible en raison du manque d'accès aux soins (infrastructures, vaccins), à l'eau potable, aux logements décentes, etc.

Causalité implique forte corrélation, tandis que le contraire est généralement faux.

4 Conditionnement de variables aléatoires

4.1 Probabilité conditionnelle

Définition :

Soit A, B deux évènements tels que $\mathbb{P}(B) > 0$. On appelle **probabilité conditionnelle de A sachant B** le réel

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Proposition :

Soit $B \in \mathcal{A}$ avec $\mathbb{P}(B) > 0$. L'application $A \mapsto \mathbb{P}(A | B)$ définit une probabilité sur $(\Omega, \mathcal{A})$.

Preuve :

Il s'agit de vérifier les trois axiomes de Kolmogorov.

- Positivité : Pour tout $A \in \mathcal{A}$, puisque $\mathbb{P}(A \cap B) \geq 0$ et $\mathbb{P}(B) > 0$, on a bien $\mathbb{P}(A | B) \geq 0$.
- Normalisation : On a $\mathbb{P}(\Omega | B) = \frac{\mathbb{P}(\Omega \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1$.
- Sigma-additivité : Soit $(A_n)_{n \geq 1}$ une suite d'évènements deux à deux disjoints. On a

$$\begin{aligned} \mathbb{P}\left(\bigcup_{n \geq 1} A_n \mid B\right) &= \frac{\mathbb{P}\left(\bigcup_{n \geq 1} A_n \cap B\right)}{\mathbb{P}(B)} \\ &= \frac{\mathbb{P}\left(\bigcup_{n \geq 1} (A_n \cap B)\right)}{\mathbb{P}(B)} \\ &= \frac{\sum_{n \geq 1} \mathbb{P}(A_n \cap B)}{\mathbb{P}(B)} \quad (\text{sigma-additivité de } \mathbb{P}, \text{ les } A_n \cap B \text{ étant disjoints}) \\ &= \sum_{n \geq 1} \mathbb{P}(A_n | B). \end{aligned}$$

Proposition – Formule des probabilités totales :

Soit $(A_i)_{i \in I}$ un système complet d'évènements, i.e. une partition de Ω en évènements de probabilité strictement positive. Alors, pour tout $B \in \mathcal{A}$,

$$\mathbb{P}(B) = \sum_{i \in I} \mathbb{P}(B | A_i) \mathbb{P}(A_i).$$

Preuve :

On a

$$\begin{aligned} \mathbb{P}(B) &= \mathbb{P}(B \cap \Omega) && (\text{car } B \cap \Omega = B) \\ &= \mathbb{P}\left(B \cap \bigcup_{i \in I} A_i\right) && (\text{car } (A_i)_{i \in I} \text{ est un système complet d'évènements}) \\ &= \mathbb{P}\left(\bigcup_{i \in I} B \cap A_i\right) && (\text{Distributivité de l'opérateur d'intersection}) \\ &= \sum_{i \in I} \mathbb{P}(B \cap A_i) && (\text{Par } \sigma\text{-additivité}) \\ &= \sum_{i \in I} \mathbb{P}(B | A_i) \mathbb{P}(A_i) \end{aligned}$$

Effectivement, la σ -additivité s'applique car $(B \cap A_i)_{i \in I}$ est une famille d'événements deux à deux disjoints car

$$\begin{cases} \forall i, j \in I, i \neq j \implies A_i \cap A_j = \emptyset & (\text{Par hypothèse}) \\ \forall i \in I, B \cap A_i \subset A_i \end{cases}$$

en particulier,

$$\forall i, j \in I, i \neq j \implies (B \cap A_i) \cap (B \cap A_j) \subset A_i \cap A_j = \emptyset.$$

Proposition – Formule de Bayes :

Soit $(A_i)_{i \in I}$ un système complet d'événements et $B \in \mathcal{A}$ tel que $\mathbb{P}(B) > 0$. Alors, pour tout $j \in I$,

$$\mathbb{P}(A_j | B) = \frac{\mathbb{P}(B | A_j) \mathbb{P}(A_j)}{\sum_{i \in I} \mathbb{P}(B | A_i) \mathbb{P}(A_i)}.$$

Preuve :

On a, en vertu de la formule des probabilités totales,

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(A \cap B_j)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A | B_j) \mathbb{P}(B_j)}{\sum_{i \in I} \mathbb{P}(A | B_i) \mathbb{P}(B_i)}.$$

4.2 Loi conditionnelle

Définition :

Soit $X, Y \in L(\Omega)$ deux variables aléatoires discrètes. On appelle, pour tout $y \in Y(\Omega)$ tel que $\mathbb{P}(Y = y) > 0$, **loi conditionnelle de X sachant $Y = y$** la loi de probabilité définie par

$$\forall x \in X(\Omega), \quad \mathbb{P}(X = x | Y = y) = \frac{\mathbb{P}(X = x \cap Y = y)}{\mathbb{P}(Y = y)}.$$

Définition :

Soit $X, Y \in L(\Omega)$ deux variables aléatoires continues de densité jointe $f_{X,Y}$. On appelle, pour tout $y \in \mathbb{R}$ tel que $f_Y(y) > 0$, **densité conditionnelle de X sachant $Y = y$** , la fonction définie par

$$\forall x \in X(\Omega), \quad f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}.$$

Proposition :

La fonction $f_{X|Y=y}$ est bien une densité de probabilité, i.e. elle est positive et vérifie

$$\int_{\mathbb{R}} f_{X|Y=y}(x) dx = 1.$$

Preuve :

La positivité est immédiate. De plus,

$$\begin{aligned} \int_{\mathbb{R}} f_{X|Y=y}(x) dx &= \int_{\mathbb{R}} \frac{f_{X,Y}(x, y)}{f_Y(y)} dx \\ &= \frac{1}{f_Y(y)} \int_{\mathbb{R}} f_{X,Y}(x, y) dx \\ &= \frac{f_Y(y)}{f_Y(y)} \end{aligned} \quad (\text{définition de la densité marginale})$$

$$= 1.$$

Proposition – Formule des probabilités totales pour les densités :

Soit $X, Y \in L(\Omega)$ admettant une densité jointe. Alors

$$\forall x \in X(\Omega), \quad f_X(x) = \int_{\mathbb{R}} f_{X|Y=y}(x) f_Y(y) dy.$$

Preuve :

On a, en vertu de la définition de la densité conditionnelle et de la densité marginale,

$$\begin{aligned} \int_{\mathbb{R}} f_{X|Y=y}(x) f_Y(y) dy &= \int_{\mathbb{R}} \frac{f_{X,Y}(x, y)}{f_Y(y)} \cdot f_Y(y) dy \\ &= \int_{\mathbb{R}} f_{X,Y}(x, y) dy \\ &= f_X(x). \end{aligned}$$

4.3 Espérance conditionnelle

Définition :

Soit $X, Y \in L^1(\Omega)$ deux variables aléatoires. On appelle **espérance conditionnelle de X sachant $Y = y$** :

- Dans le cas discret, pour tout $y \in Y(\Omega)$ tel que $\mathbb{P}(Y = y) > 0$:

$$\mathbb{E}(X | Y = y) = \sum_{x \in X(\Omega)} x \mathbb{P}(X = x | Y = y).$$

- Dans le cas continu, pour tout $y \in \mathbb{R}$ tel que $f_Y(y) > 0$:

$$\mathbb{E}(X | Y = y) = \int_{\mathbb{R}} x f_{X|Y=y}(x) dx.$$

Proposition – Formule de l'espérance totale :

Soit $X, Y \in L^1(\Omega)$. Alors

$$\mathbb{E}(X) = \mathbb{E}[\mathbb{E}(X | Y)].$$

Plus explicitement :

- Dans le cas discret :

$$\mathbb{E}(X) = \sum_{y \in Y(\Omega)} \mathbb{E}(X | Y = y) \mathbb{P}(Y = y).$$

- Dans le cas continu :

$$\mathbb{E}(X) = \int_{\mathbb{R}} \mathbb{E}(X | Y = y) f_Y(y) dy.$$

Preuve :

On traite le cas discret. On a

$$\begin{aligned} \sum_{y \in Y(\Omega)} \mathbb{E}(X | Y = y) \mathbb{P}(Y = y) &= \sum_{y \in Y(\Omega)} \left(\sum_{x \in X(\Omega)} x \mathbb{P}(X = x | Y = y) \right) \mathbb{P}(Y = y) \\ &= \sum_{y \in Y(\Omega)} \sum_{x \in X(\Omega)} x \frac{\mathbb{P}(X = x \cap Y = y)}{\mathbb{P}(Y = y)} \cdot \mathbb{P}(Y = y) \\ &= \sum_{y \in Y(\Omega)} \sum_{x \in X(\Omega)} x \mathbb{P}(X = x \cap Y = y) \end{aligned}$$

$$\begin{aligned}
 &= \sum_{x \in X(\Omega)} x \sum_{y \in Y(\Omega)} \mathbb{P}(X = x \cap Y = y) \\
 &= \sum_{x \in X(\Omega)} x \mathbb{P}(X = x) \quad (\text{loi marginale de } X) \\
 &= \mathbb{E}(X).
 \end{aligned}$$

On admet le résultat dans le cas continu (démonstration analogue).

Proposition – Formule des probabilités totales (version continue) :

Soit $X \in L(\Omega)$ de densité f_X . Alors, pour tout $B \in \mathcal{A}$,

$$\mathbb{P}(B) = \int_{\mathbb{R}} \mathbb{P}(B \mid X = x) f_X(x) dx.$$

Preuve :

Soit $B \in \mathcal{A}$. On a

$$\begin{aligned}
 \mathbb{P}(B) &= \mathbb{E}[\mathbf{1}_B] \\
 &= \mathbb{E}[\mathbb{E}[\mathbf{1}_B \mid X]] \quad (\text{Formule de l'espérance totale}) \\
 &= \int_{\mathbb{R}} \mathbb{E}[\mathbf{1}_B \mid X = x] f_X(x) dx \quad (\text{Théorème de transfert}) \\
 &= \int_{\mathbb{R}} \mathbb{P}(B \mid X = x) f_X(x) dx.
 \end{aligned}$$

Proposition – Formule de la variance totale :

Soit $X, Y \in L^2(\Omega)$. Alors

$$\mathbb{V}(X) = \mathbb{E}[\mathbb{V}(X \mid Y)] + \mathbb{V}(\mathbb{E}(X \mid Y)),$$

où l'on définit $\mathbb{V}(X \mid Y = y) = \mathbb{E}(X^2 \mid Y = y) - (\mathbb{E}(X \mid Y = y))^2$ pour tout y .

Preuve :

On a, en notant $g(y) = \mathbb{E}(X \mid Y = y)$ pour alléger les notations,

$$\begin{aligned}
 \mathbb{E}[\mathbb{V}(X \mid Y)] + \mathbb{V}(\mathbb{E}(X \mid Y)) &= \mathbb{E}[\mathbb{E}(X^2 \mid Y) - g(Y)^2] + \mathbb{E}[g(Y)^2] - (\mathbb{E}[g(Y)])^2 \\
 &= \mathbb{E}[\mathbb{E}(X^2 \mid Y)] - \mathbb{E}[g(Y)^2] + \mathbb{E}[g(Y)^2] - (\mathbb{E}[g(Y)])^2 \\
 &= \mathbb{E}(X^2) - (\mathbb{E}(X))^2 \quad (\text{Formule de l'espérance totale}) \\
 &= \mathbb{V}(X).
 \end{aligned}$$

Proposition – Propriétés de l'espérance conditionnelle :

Soit $X, Y, Z \in L^1(\Omega)$ et $\lambda \in \mathbb{R}$. Les assertions suivantes sont vérifiées :

- 1) $\mathbb{E}(\lambda X + Z \mid Y) = \lambda \mathbb{E}(X \mid Y) + \mathbb{E}(Z \mid Y).$
- 2) $X \geq 0 \text{ p.s.} \implies \mathbb{E}(X \mid Y) \geq 0 \text{ p.s.}$
- 3) $X \perp\!\!\!\perp Y \implies \mathbb{E}(X \mid Y) = \mathbb{E}(X).$

Preuve :

- 1) On traite le cas continu, le cas discret étant analogue en remplaçant les intégrales par des sommes. Pour tout $y \in \mathbb{R}$ tel que $f_Y(y) > 0$, on a

$$\mathbb{E}(\lambda X + Z \mid Y = y) = \int_{\mathbb{R}} (\lambda x + z) f_{X|Y=y}(x) dx$$

$$\begin{aligned}
 &= \lambda \int_{\mathbb{R}} x f_{X|Y=y}(x) dx + \int_{\mathbb{R}} z f_{Z|Y=y}(z) dz \\
 &= \lambda \mathbb{E}(X | Y = y) + \mathbb{E}(Z | Y = y).
 \end{aligned}$$

- 2) On traite le cas continu. Soit $y \in \mathbb{R}$ tel que $f_Y(y) > 0$. Puisque $X \geq 0$ p.s., on a $x f_{X|Y=y}(x) \geq 0$ pour presque tout $x \in \mathbb{R}$. Par positivité de l'intégrale, il vient

$$\mathbb{E}(X | Y = y) = \int_{\mathbb{R}} x f_{X|Y=y}(x) dx \geq 0.$$

- 3) On traite le cas continu. Puisque $X \perp\!\!\!\perp Y$, on a $f_{X,Y}(x,y) = f_X(x) f_Y(y)$, donc $f_{X|Y=y}(x) = f_X(x)$. Ainsi,

$$\mathbb{E}(X | Y = y) = \int_{\mathbb{R}} x f_{X|Y=y}(x) dx = \int_{\mathbb{R}} x f_X(x) dx = \mathbb{E}(X).$$

Ce résultat étant valable pour tout y , on conclut que $\mathbb{E}(X | Y) = \mathbb{E}(X)$.

5 Vecteurs gaussiens

Les sections précédentes ont posé les fondements de l'étude des couples de variables aléatoires : loi jointe, indépendance, covariance, espérance conditionnelle. Cette section franchit une étape supplémentaire en étudiant une famille de lois multidimensionnelles d'une richesse remarquable : les vecteurs gaussiens. Leur structure algébrique et probabiliste est suffisamment rigide pour que l'on puisse tout calculer explicitement, et suffisamment souple pour modéliser une très grande variété de phénomènes réels.

Dans toute cette section, on considère un vecteur aléatoire $X = (X_1, \dots, X_n)^\top$ à valeurs dans $\mathbb{R}^n$.

Définition :

On dit que $X = (X_1, \dots, X_d) \in L(\Omega)^d$ est un **vecteur gaussien** si toute combinaison linéaire de ses composantes est une variable aléatoire gaussienne (ou constante), i.e.

$$\forall \lambda_1, \dots, \lambda_d \in \mathbb{R}^d, \quad \sum_{i=1}^d \lambda_i X_i \sim \mathcal{N}(m_\lambda, \sigma_\lambda^2) \quad \text{où } m_\lambda \in \mathbb{R} \text{ et } \sigma_\lambda^2 \geq 0.$$

Remarque :

Cette définition est plus exigeante qu'il n'y paraît : il ne suffit pas que chaque composante X_i soit gaussienne. Il faut que *toute* combinaison linéaire le soit. Il existe des couples (X, Y) dont les lois marginales sont gaussiennes, mais qui ne forment pas un vecteur gaussien (voir l'exercice 41).

Définition :

Soit $X = (X_1, \dots, X_d) \in L^2(\Omega)^d$ un vecteur gaussien. On définit :

- Le **vecteur moyen** de X :

$$\mu = \mathbb{E}[X] = \begin{pmatrix} \mathbb{E}[X_1] \\ \vdots \\ \mathbb{E}[X_d] \end{pmatrix} \in \mathbb{R}^d.$$

- La **matrice de covariance** de X :

$$\Sigma = \text{Cov}(X) = \mathbb{E}[(X - \mu)(X - \mu)^\top] \in \mathcal{M}_d(\mathbb{R}),$$

$$\text{où } \Sigma_{ij} = \text{Cov}(X_i, X_j).$$

On note alors $X \sim \mathcal{N}(\mu, \Sigma)$.

Proposition – Propriétés de la matrice de covariance :

Soit $X \sim \mathcal{N}(\mu, \Sigma) \in L(\Omega)^d$ un vecteur gaussien. Alors :

- 1) Σ est symétrique.
- 2) Σ est positive semi-définie, i.e. : $\forall \lambda \in \mathbb{R}^d, \lambda^\top \Sigma \lambda \geq 0$.
- 3) $\forall i \in \llbracket 1, n \rrbracket, \Sigma_{ii} = \mathbb{V}(X_i) \geq 0$.

Preuve :

- 1) La symétrie découle immédiatement de la symétrie de la covariance,

$$\forall i, j \in \llbracket 1, d \rrbracket, \text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i).$$

- 2) Pour tout $\lambda \in \mathbb{R}^n$,

$$\begin{aligned} \lambda^\top \Sigma \lambda &= \lambda^\top \mathbb{E}[(X - \mu)(X - \mu)^\top] \lambda \\ &= \mathbb{E}[\lambda^\top (X - \mu)(X - \mu)^\top \lambda] \\ &= \mathbb{E}[(\lambda^\top (X - \mu))^2] \geq 0. \end{aligned}$$

- 3) Pour tout $i \in \llbracket 1, n \rrbracket, \Sigma_{ii} = \text{Cov}(X_i, X_i) = \mathbb{V}(X_i)$.

Théorème – Stabilité par transformation affine :

Soit $X \sim \mathcal{N}(\mu, \Sigma)$ un vecteur gaussien de $\mathbb{R}^d$, $A \in \mathcal{M}_{n,d}(\mathbb{R})$ et $b \in \mathbb{R}^n$. Le vecteur $Y = AX + b$ est gaussien et

$$Y = AX + b \sim \mathcal{N}(A\mu + b, A\Sigma A^\top).$$

Preuve :

Montrons que Y est gaussien. Soit $\lambda \in \mathbb{R}^n$. On a

$$\begin{aligned} \lambda^\top Y &= \lambda^\top (AX + b) \\ &= \underbrace{(A^\top \lambda)^\top}_{\in \mathbb{R}^d} X + \underbrace{\lambda^\top b}_{\in \mathbb{R}}. \end{aligned}$$

Puisque $(A^\top \lambda)^\top X$ est gaussien en tant que combinaison linéaire de variables aléatoires gaussiennes (X est gaussien) et que $\lambda^\top b$ est une constante, $\lambda^\top Y$ est également gaussien. Ainsi Y est un vecteur gaussien.

De plus,

$$\begin{aligned} \forall i \in \llbracket 1, n \rrbracket, \mathbb{E}[Y]_i &= \mathbb{E}\left[\sum_{k=1}^d A_{ik} X_k\right] \\ &= \sum_{k=1}^d A_{ik} \mathbb{E}[X_k] \\ &= (A \mathbb{E}[X])_i \end{aligned}$$

Par conséquent,

$$\begin{aligned} \mathbb{E}[Y] &= \mathbb{E}[AX] + b \\ &= A \mathbb{E}[X] + b \\ &= A\mu + b. \end{aligned}$$

Finalement,

$$\begin{aligned} \text{Cov}(Y) &= \mathbb{E}[(Y - \mathbb{E}[Y])(Y - \mathbb{E}[Y])^\top] \\ &= \mathbb{E}[A(X - \mu)(X - \mu)^\top A^\top] \\ &= A \mathbb{E}[(X - \mu)(X - \mu)^\top] A^\top \\ &= A\Sigma A^\top. \end{aligned} \quad (\forall i, j \in \llbracket 1, d \rrbracket, \Sigma_{ij} = \mathbb{E}[(X_i - \mu_i)(X_j - \mu_j)^\top])$$

Corollaire – Lois marginales :

Soit $X = (X_1, \dots, X_n)^\top \sim \mathcal{N}(\mu, \Sigma)$. Pour tout $i \in \llbracket 1, n \rrbracket$, on a

$$X_i \sim \mathcal{N}(\mu_i, \Sigma_{ii}).$$

Preuve :

Il suffit d'appliquer le théorème précédent avec $A = e_i^\top$ (le i -ème vecteur de la base canonique de $\mathbb{R}^n$, vu comme une matrice ligne $1 \times n$) et $b = 0$. On obtient

$$X_i = e_i^\top X \sim \mathcal{N}(e_i^\top \mu, e_i^\top \Sigma e_i) = \mathcal{N}(\mu_i, \Sigma_{ii}).$$

Théorème – Caractérisation de l'indépendance :

Soit (X, Y) un vecteur gaussien. Alors

$$X \perp\!\!\!\perp Y \iff \text{Cov}(X, Y) = 0.$$

Preuve :

Le sens direct est toujours vrai

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

$$\begin{aligned} &= \mathbb{E}(X)\mathbb{E}(Y) - \mathbb{E}(X)\mathbb{E}(Y) \\ &= 0 \end{aligned} \quad (X \perp\!\!\!\perp Y)$$

Réciproquement, supposons $\text{Cov}(X, Y) = 0$. Pour tout $a, b \in \mathbb{R}$, la variable $aX + bY$ est gaussienne (car (X, Y) est un vecteur gaussien), de variance

$$\begin{aligned} \mathbb{V}(aX + bY) &= a^2\mathbb{V}(X) + b^2\mathbb{V}(Y) + 2ab\text{Cov}(X, Y) \\ &= a^2\mathbb{V}(X) + b^2\mathbb{V}(Y). \end{aligned}$$

On admet que si $Z \sim \mathcal{N}(\mu, \sigma^2)$, alors sa fonction caractéristique est

$$\varphi_Z : t \mapsto \mathbb{E}[e^{itZ}] = \exp\left(it\mu - \frac{t^2\sigma^2}{2}\right).$$

On admet de plus que si $\varphi_{(X,Y)}(a, b) = \varphi_X(a) \cdot \varphi_Y(b)$ pour tout $a, b \in \mathbb{R}^2$, alors $X \perp\!\!\!\perp Y$.

La fonction caractéristique du vecteur (X, Y) vaut, pour tout $a, b \in \mathbb{R}$,

$$\begin{aligned} \varphi_{(X,Y)}(a, b) &= \mathbb{E}[e^{i(aX+bY)}] && \text{(Définition)} \\ &= \exp\left(i(a\mathbb{E}[X] + b\mathbb{E}[Y]) - \frac{a^2\mathbb{V}(X) + b^2\mathbb{V}(Y)}{2}\right) && (aX + bY \text{ est gaussienne}) \\ &= \exp\left(ia\mathbb{E}[X] - \frac{a^2\mathbb{V}(X)}{2}\right) \cdot \exp\left(ib\mathbb{E}[Y] - \frac{b^2\mathbb{V}(Y)}{2}\right) \\ &= \varphi_X(a) \cdot \varphi_Y(b). \end{aligned}$$

Proposition – Stabilité par somme :

Soit $X \sim \mathcal{N}(m_1, \sigma_1^2)$ et $Y \sim \mathcal{N}(m_2, \sigma_2^2)$ deux variables aléatoires **indépendantes**. Alors

$$X + Y \sim \mathcal{N}(m_1 + m_2, \sigma_1^2 + \sigma_2^2).$$

Preuve :

Puisque X et Y sont indépendantes, on a

$$\begin{aligned} \forall t \in \mathbb{R}, \varphi_{X+Y}(t) &= \varphi_X(t) \varphi_Y(t) \\ &= \exp\left(im_1t - \frac{\sigma_1^2 t^2}{2}\right) \cdot \exp\left(im_2t - \frac{\sigma_2^2 t^2}{2}\right) \\ &= \exp\left(i(m_1 + m_2)t - \frac{(\sigma_1^2 + \sigma_2^2)t^2}{2}\right). \end{aligned}$$

On reconnaît la fonction caractéristique de $\mathcal{N}(m_1 + m_2, \sigma_1^2 + \sigma_2^2)$.

Proposition – Convergence en loi de suites gaussiennes :

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires gaussiennes, où $X_n \sim \mathcal{N}(m_n, \sigma_n^2)$ pour tout $n \geq 1$.

Si $\lim_{n \rightarrow \infty} m_n = m \in \mathbb{R}$ et $\lim_{n \rightarrow \infty} \sigma_n = \sigma > 0$ alors

$$X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(m, \sigma^2).$$

Preuve :

La fonction caractéristique de X_n est

$$\varphi_{X_n} : t \mapsto \exp\left(im_nt - \frac{\sigma_n^2 t^2}{2}\right).$$

Pour tout $t \in \mathbb{R}$ fixé, on a, en vertu de la continuité de $\exp$,

$$\varphi_{X_n}(t) \xrightarrow[n \rightarrow +\infty]{} \exp\left(imt - \frac{\sigma^2 t^2}{2}\right) = \varphi_X(t), \quad \text{où } X \sim \mathcal{N}(m, \sigma^2).$$

La limite est continue en 0 (c'est une fonction caractéristique). On conclut à l'aide du théorème de Lévy, assurant que la convergence en loi de $(X_n)_{n \geq 1}$ vers X équivaut à la convergence ponctuelle des fonctions caractéristiques.